ChatGPT的本质

- 来源: https://class.imooc.com/lesson/5253#mid=104869
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: ChatGPT的本质
- 课节: 图文 1-1 ChatGPT的本质

1-1 ChatGPT的本质

ChatGPT的本质

> [!TIP] 阅读指南 理解大模型的核心原理，有助于写出更好的AI程序。本书以ChatGPT为例讲解，其他大模型（Gemini、DeepSeek等）原理相同。 本章将带你深入ChatGPT的内部，从本质、工作原理、训练过程到能力边界，用平实的语言和生动的类比，让你真正理解这个正在改变世界的技术。 现在，让我们从最根本的问题开始：ChatGPT到底是什么？

1.1 回到中学数学课：函数的本质

我想从一个你一定熟悉的概念说起：函数。还记得中学数学课上，老师在黑板上写下的那个公式吗？

$y = f(x)$ y=f(x)

=

(

)

这是函数的标准形式。给定一个输入x，通过某种规则f进行计算，得到输出y。简单，明了，优雅。那时我们学的函数，大多数是这样的：

$y = 2x + 3$ y=2x+3

-

$y = x^2$ y=x 2

x 2

x2

y = sin（x）y=sin(x)

sin

规则简单，输入输出的关系一目了然。但函数的力量，远不止于此。ChatGPT，从数学上讲，也是一个函数：

回答 = ChatGPT（问题）回答=ChatGPT(问题)

回答

你输入一个问题（输入x），ChatGPT执行某种计算（函数f），然后返回一个回答（输出y）。

这不是比喻，不是类比，而是数学意义上的精确描述。ChatGPT就是一个函数——只不过，是一个极其复杂的函数。

1.2 1750亿个参数的"旋钮"

但ChatGPT和我们在中学学的函数，有一个本质的区别。中学的函数，参数通常只有几个：

这里只有2个参数：系数"2"和常数"3"。而ChatGPT呢？它有1750亿个参数。 1750亿。这是一个什么概念？

- 比地球上的人口（80亿）多20倍
- 如果每秒数一个数，要数5000多年
- 如果用A4纸打印，每页100个数字，需要17.5亿页纸，堆起来高达17.5万米——比珠穆朗玛峰（8849米）高20倍

我第一次看到这个数字的时候，也被震撼了。我们究竟在和一个什么样的"函数"打交道？

换个角度想，一个拥有1750亿参数的模型，它是怎么"理解"你的问题，又是怎么"组织"出回答的？

为了回答这个问题，我们可以把ChatGPT想象成一个巨大的控制面板。面板上密密麻麻排列着1750亿个旋钮，每个旋钮都可以调节，每个旋钮的位置都会影响最终的输出。

回答 = f（问题，θ1，θ2，θ3，...，θ175000000000）回答=f(问题,θ1 ,θ2 ,θ3 ,...,θ175000000000)

θ1

θ2

θ3

θ175000000000

这1750亿个旋钮（参数），共同决定了ChatGPT如何理解语义、如何组织逻辑、如何选择措辞。

> [!NOTE] 关于参数数量的说明 本书中我们主要以GPT-3的1750亿参数作为讲解示例。 为什么不用最新的GPT-5.2？ 因为OpenAI从GPT-4开始就不再公开参数量等技术细节，而GPT-3是最后一个公开详细技术参数（96层网络、12288维嵌入等）的模型。GPT-3.5（与GPT3同源，是ChatGPT最初版本的基座）虽然也很重要，但它的参数量同样未公开，估计在1750亿左右。1750亿这个确切的数字，能让你更直观地理解这些概念。 不过请放心，所有GPT模型的核心原理是完全一致的——无论是1750亿参数还是现在万亿级别的参数，它们的工作机制都是相同的。而且以现在人类对Transformer架构的痴迷（后面你会了解Transformer，以及为什么我说是"痴迷"），短期内模型机制不会有太大的变化。

1.3 参数到底是什么?

说到这里，你可能会问：这些"参数"到底是什么？为什么要有这么多？

让我直接告诉你：参数是存储知识的容器。

存储知识的容器

每个参数（准确说是参数的组合）编码了语言的某种规律：

- 有些参数记录了"主语后面通常跟动词"
- 有些参数记录了"'苹果公司’ 是一家科技公司"
- 有些参数记录了"悲伤的情绪通常用某些词汇表达"

每一种语言现象，每一点世界知识，都需要一些参数来存储和表达。

1.4 语言的复杂性

现在，关键问题来了：为什么需要这么多参数?

答案很简单，也很深刻：因为语言太复杂了。

因为语言太复杂了。

语言复杂性的四个例子

让我给你举几个例子，感受一下语言的复杂性。

- 一词多义

> “这本书很重”（重量大） “这件事很重要”（重要）

同一个"重"字，在不同语境下，意思完全不同。人类当然能够理解，但是模型需要参数来捕捉这种微妙的差异。

- 指代消解

所谓指代消解，就是判断代词（如"他"、“它”、"这个"等）具体指代什么。这在人类看来很自然，但对计算机是一个复杂的推理问题。比如：

> “小明买了一个苹果手机。它的屏幕很大。”

"它"指的是什么？是苹果手机，不是小明，也不是水果苹果，而是指iPhone手机。模型需要参数来追踪这种指代关系。

- 隐含的常识

> “他把玻璃杯掉在地上，碎了。”

什么碎了？是玻璃杯，不是地板。这需要常识：玻璃杯易碎，地板不易碎。模型需要参数来存储这些常识。

- 语用学

> “你能把窗户关上吗？”

这表面上是一个疑问句，实际上是一个请求，甚至隐含着不耐烦的情绪。模型需要参数来理解这些语用规则，甚至需要结合上下文，能推测出是否有不耐烦的情绪。

这还只是最表面的复杂性。

语言的世界里，近义词之间有微妙的差异，同一个词在不同语境下意思完全不同。还有成语俗语背后的文化典故，医学、法律这些专业领域的术语……更别说人说话时的那种感觉，褒义贬义、正式口语，模

型都得学会分辨。

每一个维度，都需要大量参数来捕捉。

有人做过一个粗略的估算：人类语言中有数十万个词汇，数百万种常见的词语搭配，数千万个事实性知识，数亿种可能的句子结构……要让模型"理解"这一切，1750亿个参数，可能还不够。

1.5 可以解方程吗?

既然ChatGPT是一个函数，有1750亿个参数需要确定，那为什么不能像我们在学校学的那样，用解方程组的方法来求解这些参数呢?

这是一个极好的问题。让我详细解释为什么不能。

为什么不能解方程组?

先回顾一下中学的解方程组是怎么做的：

假设我们有一个函数： $y = a\,x + b$ y=ax+b。我们的目标是求出参数 a a 和 b b：

第1步：根据已知条件列方程

已知条件：

- 当 x = 1 x=1 时， y = 5 y=5
- 当 x = 2 x=2 时， y = 7 y=7

可以列出方程组：

{ 5 = a · 1 + b 7 = a · 2 + b { 5=a·1+b 7=a·2+b

第2步：直接求解

用消元法，直接算出： a = 2 a=2， b = 3 b=3

b=3

a=2

完成！我们找到了精确的参数值。那么，能用同样的方法求ChatGPT的参数吗？不太实际。有以下几个问题。

- 问题一，方程太复杂

中学的方程组是线性的： 2 x + 3 y = 1 0 2x+3y=10

但ChatGPT的"方程"是96层嵌套的非线性系统：

输出 = 第96层 (. . . 第2层 (第1层 (输入))) 输出=第96层(...第2层(第1层(输入)))

其中每一层都有数十亿个参数，且包含ReLU这样的非线性转换。这是一个极度复杂的非线性系统，没有解析解（就是没有公式可以直接算出答案）。

> [!NOTE] 术语说明：什么是线性和非线性？ 线性：输入和输出成正比关系。比如买水果： 买1斤苹果5元，买2斤10元，3斤15元 → 成正比 非线性：输入和输出的关系有转折。比如： 学习时间与成绩：从0小时到1小时，成绩大幅提升；但从10小时到11小时，可能几乎不增长了 药物剂量：1粒没效果，2粒有效，3粒可能中毒 → 不是简单的翻倍关系 ReLU函数：负数全部变成0，正数保持不变 → 在零点有个"拐弯"

那为什么ChatGPT需要非线性?

因为语言规律不是简单的正比关系。比如"喜欢"这个词：

- 在"我喜欢你"里是亲密
- 在"我喜欢吃苹果"里是偏好
- 在"我喜欢得很"里是讽刺

同一个词，不同语境意思完全不同。这种复杂关系必须用非线性函数来表达。

- 问题二，计算量无法承受

即使理论上能列出方程组，求解1750亿个未知数的方程组：

传统方法（如高斯消元法）的计算复杂度是 O (n 3) O(n 3)。对于1750亿，就是 (1 7 5 0 亿) 3 (1750亿) 3 的计算量。这个数字大到宇宙中的原子数都不够用来计数

n3

1.6 ■ 学点英语

中文	English	音标	说明
函数	Function	/ˈfʌŋkʃən/	输入到输出的映射关系
参数	Parameter	/pəˈræmɪtər/	模型中可学习的权重和偏置
大模型	Large Language Model (LLM)	/lɑːdʒ ˈlæŋgwɪdʒ ˈmɒdl/	基于海量数据训练的神经网络语言模型
线性	Linear	/ˈlɪniər/	输入输出成正比，可加可乘的简单关系
非线性	Nonlinear	/nɒnˈlɪniər/	输入输出有转折和拐弯的复杂关系
一词多义	Polysemy	/pəˈlɪsəmi/	同一词语在不同语境中含义不同
指代消解	Anaphora Resolution	/əˈnæfərə ˌrezəˈluːʃən/	判断代词（他/它/这个）具体指代什么
语用学	Pragmatics	/prægˈmætɪks/	研究语境如何影响语言的理解和使用
分布式编码	Distributed Representation	/dɪˈstrɪbjuːtɪd ˌreprɪzenˈteɪʃən/	知识分散在一组参数组合中而非一对一存储
解析解	Closed-form Solution	/kləʊzd fɔːm səˈluːʃən/	可以直接用公式算出的精确数学解
非线性系统	Nonlinear System	/nɒnˈlɪniər ˈsɪstəm/	输出与输入不成正比的复杂系统
激活函数	Activation Function	/ˌæktɪˈveɪʃən ˈfʌŋkʃən/	引入非线性的关键数学操作，如ReLU