参数的演化

- 来源: https://class.imooc.com/lesson/5253#mid=104872
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: ChatGPT的本质
- 课节: 图文 1-7 参数的演化

1-7 参数的演化

参数的演化

3.1 参数的演化:从"记住答案"到"理解规律"

前面我们讲了训练的原理:模型通过调整参数,让预测越来越准确。但这里有一个关键问题:

模型是在"死记硬背答案",还是真的"学会了语言规律"?

让我用具体例子帮你理解这个区别。

两种学习方式的对比

想象你在学英语:

- 方式一：死记硬背

看到问题："The cat ___ fish." 记住答案： “eats”

看到问题："The dog ___ bones." 记住答案： “eats”

看到问题："The bird ___ seeds." 记住答案： “eats”

你只是把每个问题和答案对应起来，但不知道为什么。

- 方式二：理解规律

看到多个例子后，你逐渐意识到：

- “猫”、“狗”、"鸟"都是动物
- 它们后面用 “eats” 而不是 “eat”

- 这是"第三人称单数加s"的规律

现在遇到新问题："The rabbit ___ carrots." 你能推断：应该是 “eats”，虽然没见过这个具体句子

这两种方式的区别在哪？关键在于泛化能力——死记硬背只能处理见过的问题，而理解规律能应对没见过的新情境。

模型的学习方式：从记忆到泛化

如果你是GPT的设计者，面对数十亿GB的训练文本，你会让模型采用哪种学习方式？

直觉上，方式一似乎更简单——见过什么就记住什么。但实际上，这条路根本走不通：

这条路根本走不通

为什么死记硬背行不通？主要有三个原因：

- 训练数据太庞大 数十亿GB的文本，包含无数种表达方式，即使1750亿个参数也记不住每个句子。
- 见过的永远是有限的 互联网有无穷多的新表达，用户的提问千奇百怪，死记硬背只能应付训练集。
- 泛化才是真正的智能 人类不是记住每个句子，而是掌握了语言的规律，模型也必须这样做。

所以，GPT别无选择，只能采用方式二——理解规律。

换句话说：参数存储的不是答案，而是知识。

参数存储的不是答案，而是知识

知识是抽象的规律，答案只是规律的具体体现。模型学会了规律，就能应对无穷变化的问题——这才是真正的智能。这也是为什么ChatGPT或者同类大模型感觉很聪明的原因。

参数演化的实例：从随机到规律

让我用一个具体例子展示这个过程。

假设有一组参数负责处理"动物吃什么"的关联：

```
参数组 = [0.0123, -0.0456, 0.0789, ...]（随机值）
模型不知道任何关联

1
2
```

```
参数组 = [0.0125, -0.0454, 0.0791, ...]
微调了一点点，但还是看不出规律

1
2
```

```
参数组 = [0.0345, -0.0234, 0.1567, ...]
模型开始"意识到"：动物和食物之间有关联

1
2
```

```
参数组 = [0.2567, -0.1234, 0.4321, ...]
模型已经"学会"了规律：

- 看到"猫"，会想到"鱼"
- 看到"狗"，会想到"骨头"
- 甚至遇到没见过的动物，也能推测其食物
```

```
参数组 = [0.3124, -0.0987, 0.5678, ...]（稳定下来）
这些参数现在编码了"动物-食物"的语义关联

1
2
```

> [!NOTE] 补充说明：什么是"累计遇到1000次"？ 这里的"1000次"不是指连续1000次出现同一个句子，而是指： 在整个训练过程中，模型累计遇到了1000次包含"猫-鱼"这种语义关联的文本。 这些文本可能是各种不同的表述： “猫吃鱼” “猫喜欢吃鱼” “小猫咪正在吃一条鱼” “这只猫抓了一条鱼” “猫的食物通常是鱼” ... 而且这些文本分散在整个训练数据集的不同位置，不是连续出现的。

参数不是记住了"猫→鱼"这个答案，而是学会了"动物与其食物之间有关联"这个规律。

训练完成：参数固化

经过数周的训练，花费数百万美元的算力，1750亿个参数终于稳定下来。

这时，训练停止，参数被"冻结":

> 参数$_1$ = 0.2341 ← 固定了 参数$_2$ = -0.5678 ← 固定了 ... 参数$_{175000000000}$ = 0.8901 ← 固定了

这就是我们今天使用的ChatGPT。

当你问它问题时，它不会再调整参数，而是用这1750亿个已经训练好的参数，计算你的问题的答案。就像一个学生读完了所有的书，考试结束了，知识已经内化在脑海里，不会再变了。

3.2 黑箱问题：没有人知道每个参数的含义

这里有一个有趣的事实：

虽然我们知道这1750亿个参数存储了语言知识，但没有人能确切地说出每个参数代表什么。

这些参数是通过训练"自然涌现"出来的，而不是人工设计的。我们能看到整体的效果（ChatGPT能流畅对话），但很难解释局部的机制（为什么参数$_{234567}$这个位置恰好是0.5678这个值）。

让我深入探讨一下这个"不可解释性"问题，因为它触及了现代AI的一个根本性困境。

人类创造了自己也不完全理解的工具

> 你问一个AI工程师：“为什么ChatGPT对这个问题给出这样的答案？” 工程师：“因为那1750亿个参数经过计算，产生了这个答案。” 你：“为什么是这个答案？” 工程师：“因为参数是这样设置的。” 你：“为什么参数是这样设置的？” 工程师：“因为训练数据和优化算法让它收敛到这个状态。” 你：“但具体哪个参数负责哪部分逻辑？” 工程师："……我们不知道。"

这不是开玩笑。**我们真的不知道每个参数到底在做什么。**具体来说，我们无法精确地回答：

- 参数$_{234567}$为什么是0.5678而不是0.5679
- 这个参数具体编码了什么知识
- 修改这个参数会导致什么变化

为什么会这样？关键在于知识的分布式存储。"猫吃鱼"这个知识，不是存储在某一个参数里，而是存储在可能数百万个参数的组合中：

```
参数123  =  0.23  ┐
参数456  = -0.45  │
参数789  =  0.67  ├─ → 这些参数的组合
...               │      共同编码了"猫-鱼"关系
参数9999 =  0.12  ┘
```

就像全息图：每一小块都包含整幅图像的信息，但都很模糊；只有组合起来，才能看清完整的图像。

与人类大脑的惊人相似

这让我想起人类大脑的一个有趣对比：

这个相似性，是巧合吗？还是说，分布式表示是智能系统的必然特征？

分布式表示是智能系统的必然特征

不可解释性的后果

这种不可解释性，带来了深刻的问题：

- 安全性问题

> 如果我们不知道模型"为什么"这样回答？ 我们怎么确保它不会给出危险的建议？ 我们怎么预防它被恶意利用？

- 可信度问题

> 在医疗、法律等关键领域： "这个AI说这个病人需要手术" 医生："为什么？ “ AI： “我的1750亿个参数计算出来的" 医生：” ……” ← 敢相信吗？

- 调试困难

> 当模型出错时： 传统软件：可以定位到具体哪一行代码有bug ChatGPT：是1750亿个参数中的哪些出了问题？无从查起

可解释AI：尝试打开黑箱

正因为这个问题如此重要， “可解释AI” (Explainable AI, XAI)成为了一个热门研究领域。

研究者们在尝试：

- 机制解释:理解Transformer内部的计算流程

机制解释

- 特征可视化:把抽象的参数变成人类能理解的概念

特征可视化

- 因果分析:找出"哪些输入导致了哪些输出"

因果分析

但坦白说，进展缓慢。1750亿个参数的复杂性，可能已经超出了人类完全理解的能力边界。

我们理解自己的思维过程吗?

当你读到这里，决定"嗯，这个例子很好理解"，这个判断是怎么在你脑海中形成的？你能说出具体是哪860亿个神经元中的哪些，以什么方式产生了这个想法吗?

不能。

人类的思维，对人类自己来说，也是一个黑箱。我们能感受到思维的结果，但很难追溯思维的过程。

也许，"理解"本身就有层次：

- 使用层面的理解:我知道怎么用它 ✓

使用层面的理解

- 功能层面的理解:我知道它能做什么 ✓

功能层面的理解

- 机制层面的理解:我知道它为什么这样工作 ？

机制层面的理解

- 原子层面的理解:我知道每个部件的精确作用 ✗

原子层面的理解

对ChatGPT，我们有前两层的理解，但第三第四层很模糊。对人脑，我们也是如此。这或许说明：复杂智能系统，必然带有某种程度的不可解释性。

而我们，正在学习与这种不确定性共处——既利用AI的强大能力，又警惕它的不可预测性。

3.3 关于大模型参数数量：一个持续增长的天文数字

我们一直在说"1750亿个参数"，这里需要明确说明一下：

1750亿是GPT-3的参数量，这是在2020年公开的数据。而现在你用的ChatGPT，已经升级到了GPT-5.5（2026年4月发布），参数量已经远超这个数字。

GPT-5.5是OpenAI迄今最智能的模型，核心突破在于大幅升级的Agent智能体能力，能精准理解用户模糊指令，自主规划、调用工具完成复杂任务。

未来，这个数字可能还会继续增长。但无论数字多大，本质不变：它们都是用参数存储知识，通过训练学习语言规律的函数。

各代GPT模型的参数量

```
GPT-1 (2018):      1.17亿参数
GPT-2 (2019):      15亿参数          ← 增长13倍
GPT-3 (2020):      1750亿参数        ← 增长117倍
GPT-3.5 (2022):    未公开（估计1750亿左右）
GPT-4 (2023):      未公开
GPT-5 (2025):      未公开
GPT-5.1 (2025.11): 未公开
GPT-5.5 (2026.04): 未公开（最新旗舰）
```

为什么OpenAI不公开新版本的参数量?

从GPT-4开始，OpenAI就不再公布参数量了。官方解释是：

- 竞争原因:参数量是核心竞争力，不想被竞争对手知道

竞争原因

- 安全考虑:避免恶意攻击者利用模型结构信息

安全考虑

根据一些分析和泄露信息：

- GPT-4估计: 1万亿-10万亿参数

GPT-4估计

- GPT-5/5.1: 完全未知，可能更多，也可能优化了架构

GPT-5/5.1

- GPT-5.5: 完全未知（2026年4月发布，核心突破在Agent能力）

大模型参数量对比与符号解释

```
Google:
├─ PaLM (2022):        5400亿参数
├─ PaLM 2 (2023):      未公开
├─ Gemini Ultra (2024): 未公开
├─ Gemini 2.5 (2025):   未公开
└─ Gemini 3 Pro (2025): 未公开

Anthropic:
├─ Claude 3 (2024):     未公开
├─ Claude 4 (2025):     未公开
└─ Claude Opus 4.5 (2025): 未公开（旗舰）

国内：
├─ 阿里通义千问：
│  ├─ Qwen3-Max (2025):  超万亿参数（旗舰）
│  ├─ Qwen3-235B (MoE):  总参数2350亿，激活220亿
│  ├─ Qwen3-Next (2025): 总参数800亿，仅激活30亿
│  ├─ Qwen3.5-Plus:      多模态，速度更快
│  └─ Qwen3.6系列 (2026): Max/Plus/Flash
│
├─ DeepSeek:
│  ├─ DeepSeek-V3 (2024):    总参数6710亿
│  ├─ DeepSeek-V3.2 (2025):  总参数6850亿
│  ├─ DeepSeek-V4-Pro (2026): 总参数1.6万亿，每token激活490亿（开源旗舰）
│  └─ DeepSeek-V4-Flash (2026): 总参数2840亿，每token激活130亿（高效开源）
│
└─ 智谱：
   ├─ GLM-4 (2024):   未公开
   └─ GLM-5 (2026):   未公开
```

目前，除了DeepSeek还在坚持全模型版本开源，其他大模型都或多或少呈现初了闭源的趋势，比如阿里的Qwen，Qwen 3.6 Plus，就没有开源了。

商业模型一般都不会公布参数的具体数量；只有开源的模型可以确切的知道其参数数量。

模型命名中的参数量标识

在大模型领域，我们经常看到这样的命名：

```
Qwen3-235B
Llama-70B
GPT-3 (175B)
```

这些B、M、T是什么意思?

这是参数数量的国际通用缩写:

```
M (Million)  = 百万   = 10⁶   = 1,000,000
B (Billion)  = 十亿   = 10⁹   = 1,000,000,000
T (Trillion) = 万亿   = 10¹²  = 1,000,000,000,000
```

换算示例:

```
117M  = 117百万  = 1.17亿参数
70B   = 70十亿   = 700亿参数
175B  = 175十亿  = 1750亿参数
235B  = 235十亿  = 2350亿参数
1.8T  = 1.8万亿  = 1万8千亿参数
```

所以:

- Qwen3-235B 表示这个模型有 2350亿个参数

2350亿个参数

- Llama-70B 表示这个模型有 700亿个参数

Llama-70B

700亿个参数

- GPT-3 (175B) 表示这个模型有 1750亿个参数

GPT-3 (175B)

模型架构：Dense vs MoE

在很多模型列表中，有些模型标注了"MoE"（比如我们前面列举的一些模型）,有些是"Dense"。这是两种不同的架构设计。作为程序员，我们未必需要深入了解具体的架构，但需要知道他们的大致概念。

Dense架构（传统架构）是最常见的架构，GPT-3、GPT-4、Claude都采用这种方式:

- 每次推理使用全部参数

- 比如GPT-3有1750亿参数，每次回答问题都要用到全部1750亿

MoE架构（混合专家模型）则是一种更高效的设计。MoE全称Mixture of Experts（混合专家模型）：

- 模型包含多个"专家"子网络
- 每次推理只激活部分专家
- 不同问题激活不同专家

举例对比

```
Qwen3-235B (MoE, 2025):
总参数：2350亿
实际激活：约220亿
优势：速度接近220亿参数的模型，但能力接近2350亿

Qwen3-Next (MoE, 2025):
总参数：800亿
实际激活：仅30亿
优势：极致效率，用极小激活参数实现旗舰级性能

DeepSeek-V3 (MoE, 2024):
总参数：6710亿
实际激活：约370亿
优势：超大参数量，但推理成本可控

DeepSeek-V4-Pro (MoE, 2026):
总参数：1.6万亿
实际激活：约490亿
优势：万亿级开源旗舰，性能逼近顶级闭源模型

DeepSeek-V4-Flash (MoE, 2026):
总参数：2840亿
实际激活：约130亿
优势：极致高效，用更少激活参数实现强大性能
```

两种架构各有优势

MoE的优劣势：

- 参数量大，能力强

- 推理时只激活部分参数，速度快
- 计算成本和内存占用相对可控

劣势：

- 训练复杂度高，需要精心调优专家路由
- 不同专家可能学到不均衡的知识
- 对某些问题可能比Dense模型表现差

Dense的优劣势：

- 架构成熟，训练稳定
- 所有参数协同工作，整体性强
- 不需要复杂的专家路由机制，实现简单
- GPT-4、Claude等顶级模型都采用Dense架构
- 推理时必须使用全部参数，计算量大
- 相同参数量下，推理速度比MoE慢
- 内存占用高，部署成本更高

3.4 冷知识与趣闻

冷知识1：ChatGPT并不会因为你的使用而变聪明

很多人以为ChatGPT会"学习"你的对话，变得越来越聪明。

真相是：完全不会。

ChatGPT的生命周期分两个阶段：

当GPT-3训练好后，那么他的参数就"冻结"了；GPT-4则需要重新再训练。

这解释了为什么：

- ChatGPT不会记住你之前的对话 参数固定，不存储新信息 每次对话都是独立的（除非在同一个会话中，这涉及到上下文，我们后面会讨论，但模型本身是没有记忆能力的）
- ChatGPT不会学习新知识 参数固定，不会更新 知识截止日期是训练时的数据截止日期

- 你今天用和明天用，ChatGPT完全一样 1750亿个参数一个不变 除非OpenAI发布新版本（那是全新的模型）

那OpenAI会不会优化参数?

> ✗ 不会微调老模型:GPT-3训练完就固定了 ✓ 会训练新模型:GPT-4有更多参数，更强能力 ✗ 用户对话不改变模型:你的使用不会调整参数 ✓ 会发布新版本:但那是全新的模型，不是调整老模型

如果ChatGPT真的能从每个用户的对话中学习，全球每天数亿次对话，每次都要实时调整那1750亿个参数，计算量和成本都会是天文数字，完全无法承受!

所以，参数固定不仅是设计选择，也是工程必须。

参数固定不仅是设计选择，也是工程必须

> [!TIP] 你可以问任何一个大模型：你的训练数据截止日期是什么时候？ 目前，大部分的模型训练日期都在2024~2025年。他们的共性就是会落后于当前时间。

冷知识二：参数越多越好？没那么简单

很多人以为：参数越多，模型就越聪明。

但参数太多也会带来麻烦。

一个班级的学生从30人增加到300人：

> 每个人都需要座位 → 教室要大10倍 每个人都需要吃饭 → 食堂要大10倍 每个人都需要考试 → 改卷时间长10倍

参数也是一样：

- 训练成本爆炸
- GPT-2 (15亿参数): 训练花费 约几万美元
- GPT-3 (1750亿参数): 训练花费 约500万美元
- GPT-4 (未公开): 训练花费 估计上亿美元

参数量每增长一个数量级 → 成本可能增长10-100。

- 推理速度变慢

> 参数多 = 计算量大 = 回答得慢

这就是为什么GPT-4比GPT-3.5慢，同样的问题，GPT-4要"思考"更久

- 容易"死记硬背"

> 参数太多 = 记忆力太好，反而成了坏事

想象你准备数学考试：

理解规律（好学生）：

> 见过：3 + 5 = 8 推广：a + b = b + a （加法交换律） 新题：99 + 1 = ? → 轻松解答

死记硬背（参数过多的模型）：

> 背下：3+5=8，4+6=10，7+2=9..... 记忆：把见过的10000道题答案都背下来 新题：99 + 1 = ? → 没背过，不会做！

这就是"过拟合"：模型记住了训练数据的每个细节，但没学会背后的通用规律，遇到新情况就傻眼了。

那为什么还要做大模型？因为语言太复杂了，小模型确实应付不来。但最近出现了一个新的趋势：

> 新思路："小而精"模型 例如 LLaMA 2 (70亿参数), Mistral (7.3亿参数): 参数少，训练快，运行快 但通过更好的训练方法，能力也不差 普通电脑都能跑起来 LLaMA 2 70B 甚至能接近 GPT-3.5 的能力

不是参数越多越好，而是要找到"恰到好处"的平衡点——既能干活，又不太费钱费电。

3.5 下一节预告

现在你已经知道：ChatGPT是一个拥1750亿个参数的函数,通过训练学会了语言规律。

但它具体是怎么工作的？当你问它一个问题,它是怎么生成这些答案的?

答案就在下一节：文字接龙游戏。

3.6 扩展阅读

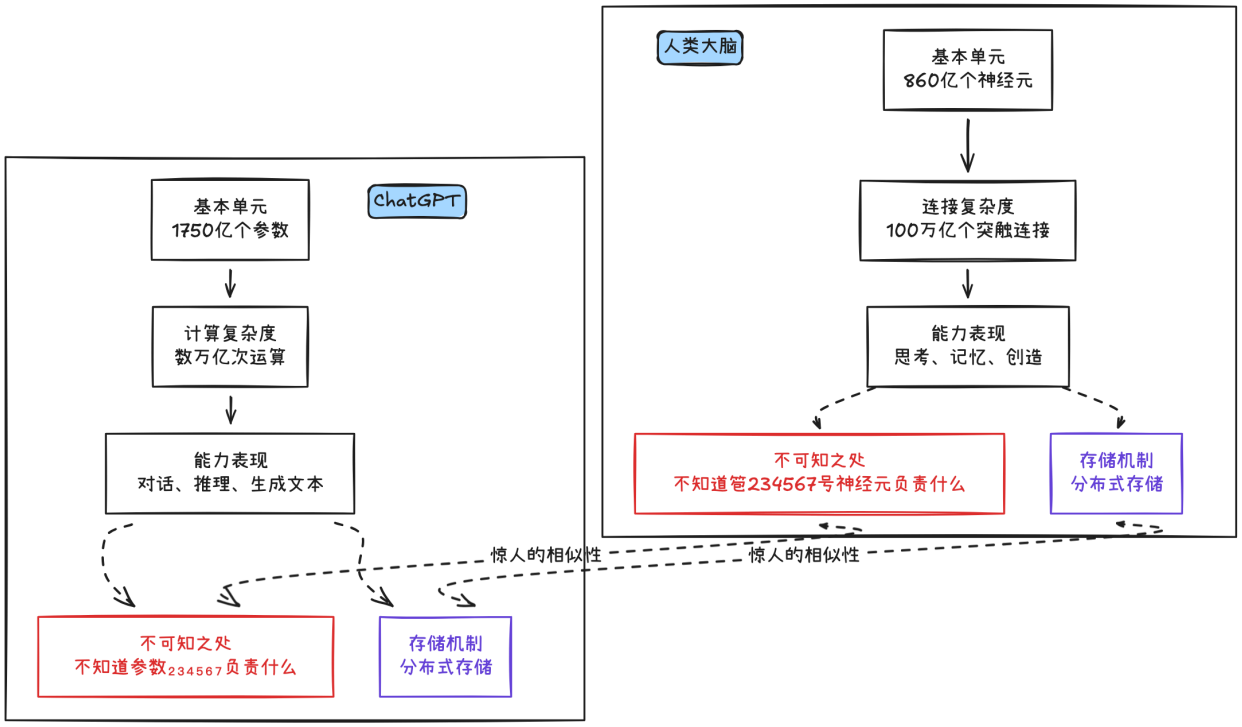
Language Models are Few-Shot Learners (GPT-3论文， 2020)

OpenAI发布的GPT-3官方论文，详细介绍了1750亿参数模型的训练过程、能力表现和局限性。论文展示了当参数量从15亿（GPT-2）跃升到1750亿（GPT-3）时带来的质变。虽然有一定技术深度，但配有大量实例，能让你从第一手资料理解"规模为什么重要"。

3.7 ■ 学点英语

中文	English	音标	说明
参数	Parameter	/pəˈræmɪtər/	模型中的可调整变量，训练后冻结固定
泛化	Generalization	/ˌdʒenrələɪˈzeɪʃən/	从训练数据学习规律并应用到新数据的能力
过拟合	Overfitting	/ˌoʊvərˈfɪtɪŋ/	模型过度记忆训练数据细节而丧失泛化能力
分布式表示	Distributed Representation	/dɪˈstrɪbjuːtɪd ˌreprɪzenˈteɪʃən/	知识分散存储在多个参数的组合中，非单个参数独立编码
推理	Inference	/ˈɪnfərəns/	用训练好的模型对新输入进行计算并输出结果
黑箱问题	Black Box Problem	/blæk bɑːks ˈprɑːbləm/	难以解释模型内部决策过程的困境
可解释AI	Explainable AI (XAI)	/ɪkˈsplænəbl eɪ aɪ/	旨在让AI决策过程可理解的研究领域
参数冻结	Parameter Freezing	/pəˈræmɪtər ˈfriːzɪŋ/	训练完成后固定参数不再更新的过程
Dense架构	Dense Architecture	/dens ˈɑːrkɪtektʃər/	每次推理使用全部参数的模型架构
MoE	Mixture of Experts	/ˈmɪkstʃər əv ˈekspɜːrts/	混合专家模型，每次推理只激活部分参数的架构

图片


ChatGPT
基本单元
1750亿个参数
计算复杂度
数万亿次运算
能力表现
对话、推理、生成文本
不可知之处
不知道参数234567负责什么
存储机制
分布式存储
人类大脑
基本单元
860亿个神经元
连接复杂度
100万亿个突触连接
能力表现
思考、记忆、创造
不可知之处
不知道管234567号神经元负责什么
存储机制
分布式存储
惊人的相似性
惊人的相似性