文字接龙（二）-概率分布的数学本质

- 来源: https://class.imooc.com/lesson/5254#mid=104874
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: 文字接龙的游戏
- 课节: 图文 1-3 文字接龙（二）-概率分布的数学本质

1-3 文字接龙（二）-概率分布的数学本质

文字接龙（二）-概率分布的数学本质

5.1 阅读指南

上一节展示了ChatGPT如何通过文字接龙逐词预测。本节深入核心问题：这些概率是如何计算出来的。将深入理解概率分布的概念，以及大模型计算每个词概率的完整流程。

5.2 概率分布的本质

用更正式的语言来描述这个过程。

每一步，大模型都在计算一个概率分布。

每一步，大模型都在计算一个概率分布

什么是概率分布?

就是对所有可能的结果，给出每个结果发生的概率。就像天气预报说： “明天有40%的概率下雨，30%的概率晴天，20%的概率阴天，10%的概率多云” 。把所有可能的天气情况列出来，每种情况都有一个概率，所有概率加起来等于100%。这就是一个概率分布。

ChatGPT做的是计算：在当前上下文中，词表中每一个词作为下一个词出现的概率。

> [!NOTE] 这里说的是"每一个词"——大模型真的会计算词表中所有词的概率（如果词表中有约20万个词，那就是真的计算20万个词的概率）。虽然大部分词的概率接近0%，但每次都要全部计算一遍。这也是为什么大模型需要强大计算能力的原因。

用数学语言表示：

> P(下一个词 | 前面所有词)

这个公式读作：

> “在给定前面所有词的情况下，下一个词是某个特定词的概率”

具体例子：

假设前面的文字是「今天」「天气」「真」，那么：

- P(好 | 今天、天气、真) = 45%
- P(不错 | 今天、天气、真) = 25%
- P(热 | 今天、天气、真) = 15%
- P(冷 | 今天、天气、真) = 8%
- P(其他词 | 今天、天气、真) = 7%

P(好 | 今天、天气、真) 读作：

> “在已知前文是[今天天气真]这五个字的情况下，下一个词是[好]的概率为45%” 。

这里只列出了几个候选词作为示例。实际上GPT会计算词表中所有词的概率，所有概率加起来等于100%。

概率的计算过程

这是整个大模型最核心的部分。简单来说：

- 把文字转成数字：每个词变成一串数字（称为"向量"）

把文字转成数字

- 通过Transformer处理：数千亿个参数对这些数字进行复杂计算

通过Transformer处理

- 输出每个词的得分：计算出词表中所有词各自的"原始得分"

输出每个词的得分

- 转换成概率：把得分转换成0-100%的概率，总和为100%

转换成概率

- 从概率中采样：不总选最高概率，而是按概率随机选择

从概率中采样

> [!TIP] 说明：此处做了简化讲解。 实际的计算过程涉及Embedding、Transformer网络、Softmax等技术细节。对这些"黑箱"内部机制感兴趣的，可以继续往下看详细讲解。不感兴趣的可以跳过下面的技术细节。核心要点在于：数千亿个参数的共同作用，最终输出了那个概率分布。

5.3 技术细节详解

大模型内部如何计算概率分布，需要详细拆解每一步。先看一张整体流程图：

把文字转成向量

计算机不能直接理解文字，所以第一步要把每个词转换成数字。这个过程称为Embedding（词嵌入）。假设需要大模型预测"今天天气真"后面的词，大致流程如下。

首先，每个词被转换成12288维向量（即12288个数字，以GPT-3为例）：

> “今天” → [0.23, -0.45, 0.67, ..., 0.12] ← 12288个数字 "天气" → [0.34, -0.12, 0.45, ..., 0.23] “真” → [-0.12, 0.56, -0.34, ..., 0.45]

> [!TIP] 不同GPT版本的向量维度： GPT-3：12288维 GPT-4/5：向量维度未公开，可能更大 维度越大，理论上能表达的语义信息越丰富

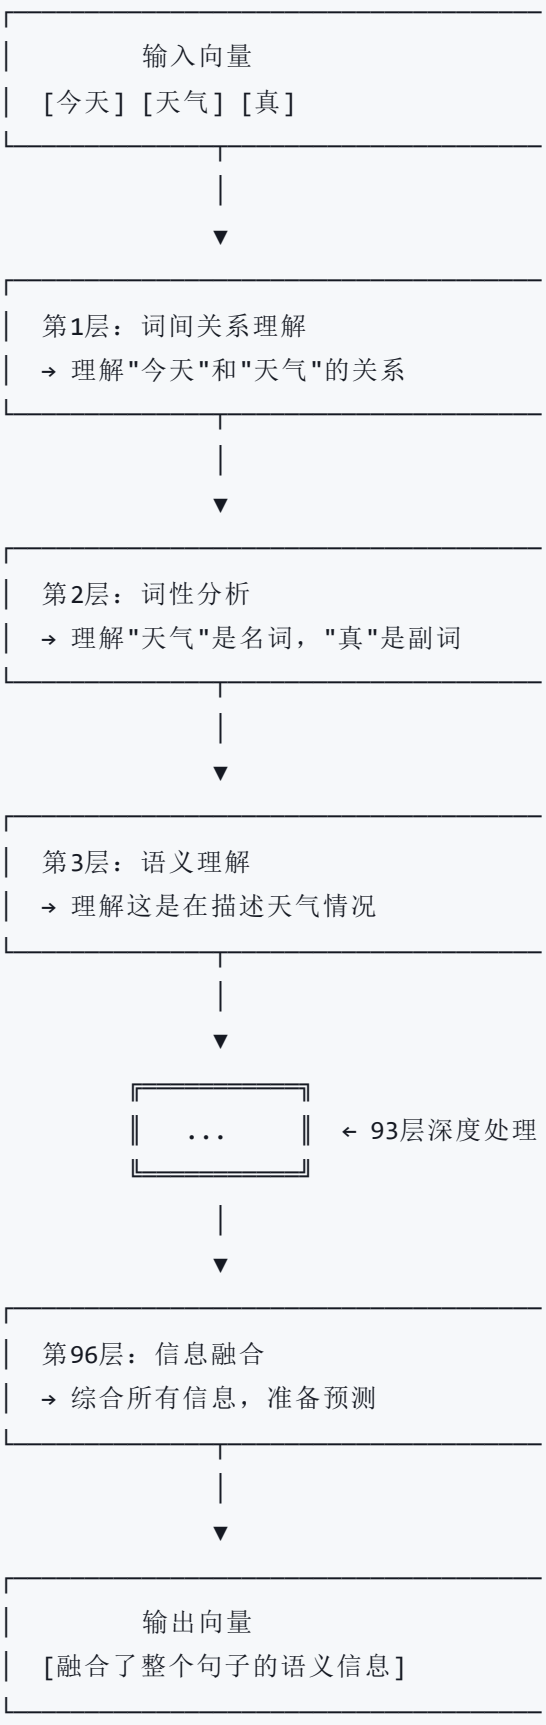
现在输入变成了一个数字矩阵：

> [[0.23, -0.45, ..., 0.12], ← “今天” （12288维） [0.34, -0.12, ..., 0.23], ← “天气” [-0.12, 0.56, ..., 0.45] ← “真”]

通过Transformer逐层处理

GPT有很多层。每一层都在做复杂的数学运算,逐步理解文字的深层含义。不同版本的层数：

- GPT-3：96层
- GPT-4/5：层数未公开，但更深



每一层都在用数千亿个参数中的一部分，对输入进行变换，逐步提取更深层的语义。

> [!TIP] 每一层实际上是Transformer架构中的模块，包含Self-Attention（让词与词"对话"）和FFN（前馈网络，进行深度计算）。对Transformer内部机制感兴趣的，可以自行深入学习相关资料。

把最后的向量转换成概率

经过多层变换后（以GPT-3的96层为例），最后一个词（“真”）对应的向量变成了：

> [1.2, -0.8, 2.3, ..., -1.5] ← 仍然是12288维

这个向量包含了"接下来应该说什么"的所有信息。

> [!NOTE] 为什么只用最后一个词（“真”）的向量？ 经过96层Transformer处理后，每个词的向量都已经融合了整个句子的上下文信息。预测"真"后面的词，所以取最后一个词对应的向量来预测。这个向量不仅包含"真"本身的信息，还通过Self-Attention机制融合了"今天"、"天气"等所有前文的信息。虽然只用了一个向量，但它已经"看到"了整个句子的信息。 如果"真"只包含自己的信息，没有全句的综合信息，一定预测不准。

然后，通过一个叫做“输出投影”的操作，把这个向量变换成词表大小的数字（GPT-3的词表约5万个词）：

```
内部向量（12288个数字）
[1.2, -0.8, 2.3, ..., -1.5]
          |
          | 输出投影（数学转换）
          ▼
变换后（约5万个数字）
[3.2,  1.5, -0.3, ...,  2.1]
 ↑     ↑     ↑          ↑
好    不错   糟糕   ...   晴朗
```

变换后的每个数字对应词表中的一个词，数字越大，说明这个词被选中的概率就越大。

> [!TIP] 这里只用"真"一个词的向量，就能计算出词表中所有词的概率。 "输出投影"和"数学转换"实际上都是线性代数中的概念——具体来说是矩阵乘法运算。线性代数是人工智能的核心数学基础，大模型内部绝大多数计算都基于矩阵运算。对AI原理感兴趣，强烈建议学习线性代数，它是理解深度学习的关键。没有兴趣也没关系，了解大致脉络以后有需要的时候再研究也不错。

Softmax变成概率

但这些数字（3.2，1.5，-0.3，...）还不是概率，原因有两点：

- 概率必须在0到1之间
- 所有概率加起来必须等于1

所以最后一步，用Softmax函数转换：

原始得分经过Softmax函数转换为概率：

```
词汇      原始得分     Softmax转换      概率
──────────────────────────────────────
好          3.2       ████████      60%
不错        1.5       ████          18%
很好        0.8       ██            10%
糟糕       -0.3       ▌              5%
...         ...       ...           ...
──────────────────────────────────────
                                    100%
```

Softmax的原理很简单：

- 得分越高，概率越大
- 把所有概率归一化，让它们加起来等于1

从概率分布中采样

有了概率分布，大模型怎么选择最终的词？

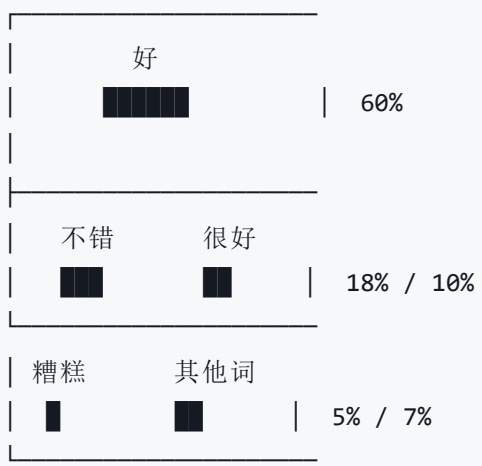
常见的理解是：总是选概率最高的词（比如"好"60%）。

大模型采用的是随机采样——按照概率分布随机选择。

随机采样

什么意思？就像转盘游戏：

转盘概率分布



转动转盘，指针停在哪里，就选哪个词。这意味着：

- 大多数时候（60%）会选"好"

大多数时候

- 但有时（18%）也会选"不错"

但有时

- 偶尔（10%）会选"很好"

偶尔

- 极少（5%）甚至会选"糟糕"

极少

> [!NOTE] 为什么不总选最高概率？这样做有什么好处？ 这个问题涉及到如何让大模型具有创造性。后面的"为什么每次回答都不一样？"小节会详细讨论。

1750亿个参数的计算结果

从"今天天气真"这五个字，经过：

- Embedding查找
- 96层Transformer变换
- Softmax归一化

最终得到词表中所有词各自的概率。这个过程在人类看来只是一瞬间，但在计算机内部，是数万亿次浮点运算。

这就是"语言模型建模语言的概率分布"的具体含义。

5.4 ■ 学点英语

中文	English	音标	说明
词嵌入	Embedding	/ɪmˈbedɪŋ/	把词映射为高维向量的过程
变换器架构	Transformer	/trænsˈfɔːrmər/	基于注意力机制的深度神经网络架构
自注意力	Self-Attention	/ˌself əˈtenʃn/	让序列中每个词与其他词计算相关性权重
前馈网络	Feed-Forward Network (FFN)	/fiːd ˈfɔːwərd ˈnetwɜːk/	Transformer每层中负责深度变换的全连接子模块
归一化指数函数	Softmax	/ˈsɒftmæks/	将任意实数向量转换为概率分布

图片

