文字接龙（四）-Token、幻觉与创造力

- 来源: https://class.imooc.com/lesson/5254#mid=104876
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: 文字接龙的游戏
- 课节: 图文 1-6 文字接龙（四）-Token、幻觉与创造力

1-6 文字接龙（四）-Token、幻觉与创造力

文字接龙（四）-Token、幻觉与创造力

> [!TIP] 阅读指南 前面几节，我们了解了文字接龙、概率分布和自回归机制。 但还有两个重要的概念需要补充： ChatGPT预测的最小单位是什么？为什么每次回答都不一样？ 在这一节，我们将解答这些问题。

7.1 Token和Tokenization：文字接龙的"最小单位"

这里我需要稍微技术性地补充一点：

ChatGPT预测的，准确说不是"词"，而是Token。

Token

什么是Tokenization（分词）？

在文本输入到ChatGPT之前，会先被切分成一个个Token。这个过程叫做Tokenization（分词）。

为什么需要这样做?

首先，你要理解一个关键约束：计算机需要一个固定大小的词表。

计算机需要一个固定大小的词表

什么意思？就是ChatGPT必须事先定好一个"词汇表"，比如包含20万个词。在预测下一个词时，只能从这20万个词里选，不能临时增加新词。但问题来了：

如果直接用"词"作为基本单位：

- 中文常用词就有几万个，加上专业术语、人名地名，轻松上百万
- 英文单词更多，几十万个，加上各种变形（walk, walking, walked...）
- 还有不断涌现的新词：“元宇宙”、“Vibe-Coding”、“直播带货”...

如果把所有词都放进词表：

- 词表会非常大（几百万个）
- 计算成本会爆炸（每次预测要算几百万个概率）
- 还是会遇到新词（永远有没见过的词）

Token的解决方案

不用"词"作为基本单位，而是用更小的"token"：

- 把常用词保留为一个token（如"今天"、“the”）
- 把不常用的词切分成几个token（如"人工智能" → “人工” + “智能”）
- 把生僻词切得更碎（如"ChatGPT" → “Chat” + “G” + “PT”）

这样，用20万个token，可以组合出无限种词汇。

用20万个token，可以组合出无限种词汇

Token是什么?

一个token可能是：

- 一个完整的中文词（如"今天"）
- 一个字（如"真"）
- 一个英文单词的一部分（如"Token"可能被切成"Token" + “ization”）
- 一个标点符号（如"," 或 “.”）

具体例子

中文：

> "今天天气真好" → 切分成：[“今天”，“天气”，“真”，“好”] → 这是4个token

而英文可能是这样：

> “Tokenization is important" → 切分成：[“Token”， “ization”，" is”，" important"] → 这是4个token（注意空格也算在token里）

Token与中英文词汇的换算大致关系：

- 中文： 1个token ≈ 1个字
- 英文： 1个token ≈ 0.75个单词

词表大小随版本增长： 从 GPT-2/3 的 5万多个，到 GPT-4 的 10万多个，再到 GPT-4o 的 20万多个。

更大的词表意味着：

- 更精细的表示：能把常用词整个存储，不用切碎

更精细的表示

- 更高的效率：减少需要处理的token数量

更高的效率

这就是token的智慧之处。

7.2 为什么每次回答都不一样?

因为ChatGPT引入了随机性。它不是每次都选概率最高的词，而是按照概率分布随机抽样。

为什么要这样设计?

- 更像人类：人类即使回答同一个问题，也会有不同的表达方式。随机性让AI的表达更生动、更自然。
- 创造力与准确性的平衡：完全确定性的回答太僵化，完全随机又太混乱。通过概率采样，在两者之间找到平衡。

这个话题非常深刻，涉及到创造力的本质、智能与随机性的关系等问题。我们会在后续专门详细讨论Temperature和另一个重要参数Top-p，以及它们如何控制AI的"创造力"。

想象下，如果ChatGPT对于同样的问题，每次回答都一字不差，那她就不配称为人工智能，她只是一个MySQL数据库。你只是在查询数据。

7.3 冷知识与趣闻

冷知识： ChatGPT其实不懂数学

很多人以为ChatGPT很擅长数学，毕竟它能解方程、算概率。

但其实它不是在"算"，而是在"猜"。

> 问： “23 + 47 = ？” ChatGPT的思路： 训练数据里见过很多"23 + 47 = 70" 预测：下一个词最可能是"70"

它不是真的在计算，只是记住了答案。

它可能连简单的计数都会错：

> 问： “strawberry这个单词里有几个r？”

ChatGPT可能答错。

因为它不是在"数字母"，而是在预测。

类似一个学生把所有题目和答案都背下来了，但并不理解数学原理——考试能过，换个题型就懵了。

不过，OpenAI很早就发现了这个问题，并找到了一个巧妙的解决方案：让ChatGPT学会“请外援”。

从GPT-4开始，ChatGPT可以调用外部工具——一个真正的计算器或Python代码执行环境。当遇到数学题时：

- 识别出这是个数学问题
- 调用Python执行真正的计算
- 把计算结果包装成自然语言返回

所以2024年你用ChatGPT算数学题，大概率不会出错——不是因为它“学会”了数学，而是因为它学会了调用工具。

2026年的新一代大模型（如GPT-5.5、Qwen3-Max、Gemini 3.0）通过强化学习和推理增强，它们已经具备了较强的原生数学计算能力，不再完全依赖调用外部工具，而是能够在模型内部进行多步骤的逻辑推导和自我纠错。

但核心原理没有变——它们仍然是在“预测”，只是通过更深的推理能力，让这种预测更加准确。对于特别复杂的数学问题，模型仍然会调用专业工具来保证100%的准确性。

7.4 下一节预告

现在你知道了ChatGPT是如何玩文字接龙游戏的：一个词一个词地预测，每次选概率最高的。

但这里有个核心问题：什么是"语言模型"？为什么ChatGPT被称为"大语言模型"？

下一节我们将正式介绍：语言模型的概念和本质。

7.5 ■ 学点英语

中文	English	音标	说明
词元	Token	/ˈtoʊkən/	模型预测的最小文本单位，可以是词、词的一部分或标点
分词	Tokenization	/ˌtoʊkənaɪˈzeɪʃən/	将原始文本切分为Token序列的过程
词表	Vocabulary	/vəˈkæbjʊleri/	模型能识别的所有Token的集合，GPT-4o约20万个
子词	Subword	/ˈsʌbwɜːd/	比完整词更小的文本单元，通过组合子词Token可用固定词表表示无限词汇
温度参数	Temperature	/ˈtemprətʃər/	控制采样随机性的超参数，温度越高输出越多样、越具创造性
嵌入	Embedding	/ɪmˈbedɪŋ/	将离散的Token映射到连续向量空间的技术，使语义相近的词在空间中靠近
自回归	Autoregressive	/ɔːtoʊrɪˈgresɪv/	模型依赖自身之前的输出作为后续输入、逐个预测下一个Token的生成方式
随机采样	Random Sampling	/ˈrændəm ˈsæmplɪŋ/	按照概率分布随机选择下一个Token而不是每次都选最高概率者