语言模型（一）-什么是语言模型

- 来源: https://class.imooc.com/lesson/5255#mid=104877
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: 语言模型
- 课节: 图文 1-1 语言模型（一）-什么是语言模型

1-1 语言模型（一）-什么是语言模型

语言模型（一）-什么是语言模型

8.1 阅读指南

前面几节，我们了解了ChatGPT如何玩文字接龙游戏。现在，让我们稍微正式一点，引入一个经常听到的术语：语言模型（Language Model）。这个词听起来很学术，但理解之后会发现它并不神秘。

8.2 人类理解世界的方式

在谈"语言模型"之前，先聊聊"模型"这个词本身。

我们生活在一个复杂得难以想象的世界里。为了理解这个世界，人类发明了一种强大的工具：用简化的数学来描述复杂的现实，这就是"模型"。

物理学中的模型

比如，一个小孩抛出一个球，球划出一道弧线落地。这个简单的动作，背后涉及无数的物理因素：球的材质、空气阻力、地球引力、风速、温度……

但牛顿给了我们一个优雅的模型：

$h = v 0 t - 1 2 g t 2$ h=v 0 t− 2 1 gt 2

t2

v0

这个公式忽略了无数细节，却能相当准确地预测球的轨迹。这就是模型的力量：用简单的数学，抓住现象的本质。

气象学中的模型

再比如，明天会不会下雨？这涉及大气中数万亿个分子的运动，地球自转，太阳辐射……

气象学家建立的模型，用几千个方程，数百万个数据点，模拟大气的运动，最终给出：

> 明天降雨概率：65%

不完美，但有用。这就是模型的价值：

> 在复杂中找到规律，在不确定中给出预测。

那么，"语言模型"呢？

类似地，人类语言是一个极其复杂的现象。当发一条朋友圈"今天emo了"，这背后涉及：

- 成长经历（学会了中文和网络文化）
- 情绪状态（正处于低落或失落的心境）
- 表达意图（想分享这种心情但不想说得太直白）
- 语言的演化历史（"emo"从英文emotional缩略而来，在中文网络语境中变成动词）
- 文化的共同理解（同龄人知道这不是"真的很悲伤"，而是一种轻松的自嘲）

这么复杂的现象，怎么用数学来描述呢？似乎不可能。

但语言模型给了我们一个数学的角度：把语言看作一个概率过程。

概率过程

8.3 语言模型的数学定义

现在，给出一个正式的定义：

> 语言模型，就是对语言概率分布的数学建模。

什么意思？拆解一下。

语言是随机过程

想象一下，正在写一篇文章。写到"今天天气"这四个字之后，下一个词可能是：

- “真好”（可能性比较大）
- “很好”（也挺常见）
- “糟糕”（也有可能）
- “紫色”（几乎不可能）

下一个词不是确定的，而是有多种可能性，每种可能性有一个概率。

语言模型计算概率

语言模型做的事情，就是用数学方法，计算出这个概率分布：

$P(w \mid C)$ P(w|C)

(

)

w

这个符号读作：“在给定前文的条件下，某个词出现的概率”。

具体例子：

> $P(\text{真好} \mid \text{今天天气}) = 0.35$ P(真好|今天天气)=0.35 $P(\text{很好} \mid \text{今天天气}) = 0.25$ P(很好|今天天气)=0.25 $P(\text{不错} \mid \text{今天天气}) = 0.15$ P(不错|今天天气)=0.15 $P(\text{糟糕} \mid \text{今天天气}) = 0.08$ P(糟糕|今天天气)=0.08 $P(\text{紫色} \mid \text{今天天气}) = 0.0001$ P(紫色|今天天气)=0.0001

这个概率分布，就是对"人类在这个上下文中会说什么"的数学建模。

为什么叫"建模"？

因为这个概率分布不是随意的，它反映了语言的内在规律。

继续用"今天天气"这个例子来说明：

规律一：语法约束

为什么 $P(\text{紫色} \mid \text{今天天气}) = 0.0001$ P(紫色|今天天气)=0.0001 这么低？

因为中文语法不允许"天气"后面接颜色词。语言模型学会了这个规律，所以给了极低的概率。

再看一个例子：

P(吃 | 我喜欢) = 0.15 P(吃|我喜欢)=0.15 P(苹果 | 我喜欢) = 0.12 P(苹果|我喜欢)=0.12
P(的 | 我喜欢) = 0.001 P(的|我喜欢)=0.001

为什么"的"概率这么低？因为"我喜欢的"这种说法不符合中文语法（虽然口语中偶尔也有，但很罕见）。

规律二：语义连贯

P(爬树 | 猫会) = 0.18 P(爬树|猫会)=0.18 P(飞 | 猫会) = 0.001 P(飞|猫会)=0.001

为什么"飞"概率这么低？因为在现实世界中，猫不会飞。语言模型从数据中学会了这个常识。

规律三：上下文相关

想象这个场景：

前文A："我买了一部新手机，它的____" 前文B：“我做了一道菜，它的____”

虽然都是"它的"，但下一个词的概率分布完全不同。

P(屏幕 | ...它的) = 0.25 P(屏幕|...它的)=0.25 P(味道 | ...它的) = 0.001 P(味道|...它的)=0.001

P(味道 | ...它的) = 0.30 P(味道|...它的)=0.30 P(屏幕 | ...它的) = 0.001 P(屏幕|...它的)=0.001

语言模型会根据更前的上下文（手机 vs 菜）来调整概率。

小结：

语言模型就是用数学的方式，把这些规律"编码"进概率分布中。这就是为什么我们说，语言模型是对语言的"建模"。

8.4 冷知识：香农游戏——语言模型的"祖先"（1948年）

你可能没想到，语言模型的思想，早在1948年就被提出了——比ChatGPT早了75年！

克劳德·香农是谁？

克劳德·香农（Claude Shannon），信息论之父，现代数字通信的奠基人。他在1948年发表了一篇划时代的论文《通信的数学理论》，奠定了整个信息时代的理论基础。

但很少有人知道，他在这篇论文中，还提出了一个有趣的"游戏"。

香农游戏：人类版的"预测下一个词"

香农做了一个实验：

> 给你一段英文文本的开头（来自小说《名利场》）： “THE ROOM WAS NOT VERY LIGHT A SMALL OBLONG READI___” 请你猜下一个字母是什么？ 如果猜对了，继续猜下一个；如果猜错了，告诉你正确答案，然后继续。 记录你猜对/猜错的次数。

他让志愿者玩这个游戏，发现了一个惊人的规律：

人类能够相当准确地预测下一个字母！

例如：

> “THE ROOM WAS NOT VERY LIGHT A SMALL OBLONG READI___” 大部分人会猜：N, G → “READING” (阅读/阅览室) 人类的大脑，自动学会了英语的： 语法规律（“a small” 后面通常是名词） 语义规律（房间不是很明亮，可能是阅览室或类似地方） 统计规律（“readi” 开头，最常见的是 “reading”）

这和语言模型有什么关系？

香农的核心洞察是：语言不是随机的，而是有规律的。这种规律可以用概率来描述。

语言不是随机的，而是有规律的。这种规律可以用概率来描述。

他甚至给出了一个数学公式，计算英语的"熵"（Entropy）——衡量语言的不确定性：

$H = -\sum P(x) \log P(x)$ H=−∑P(x)logP(x)

这就是现代语言模型的数学基础。

从香农游戏到ChatGPT

对比一下：

> 香农游戏（1948）： 人类根据经验，猜下一个字母 依靠的是大脑中积累的语言统计规律 ChatGPT（2022）： AI根据训练数据，预测下一个词 依靠的是1750亿参数中编码的语言统计规律 本质是一样的，都是在建模： P（下一个 | 前文）P(下一个|前文)

香农的预言

更神奇的是，香农在1948年就预言了：

> “如果我们能够精确计算语言的概率分布，我们就能制造出一台’写作机器’，它能够生成像人类一样的文本。”

这不就是ChatGPT吗？！

一个有趣的对比

> 1948年，香农用人类志愿者做实验： 任务：预测下一个字母 处理速度：约1个字母/秒 准确率：60-70% “参数量”：一个人类大脑 2023年，ChatGPT： 任务：预测下一个词/字母 处理速度：约100个词/秒（约500倍于人类） 准确率：在简单文本上接近90%，超过人类 参数量：1750亿

75年后，用机器实现了香农的梦想，而且远超他的预期。

如果香农还活着……

克劳德·香农于2001年去世，享年84岁。他没能看到ChatGPT的诞生。

但如果他还活着，看到自己75年前的理论，最终变成了改变世界的AI产品，他会说什么呢？

也许他会说：“我早就知道了。数学不会骗人。”

每当用ChatGPT的时候，不妨想一想：75年前，一个天才数学家，已经在纸上勾勒出了这一切的蓝图。

8.5 ■ 学点英语

中文	English	音标	说明
语言模型	Language Model	/ˈlæŋgwɪdʒ ˈmɒdl/	对语言序列概率分布进行建模的数学模型
条件概率	Conditional Probability	/kənˈdɪʃənl ˌprɒbəˈbɪləti/	在已知某事件发生的条件下另一事件发生的概率，记为P(词
联合概率	Joint Probability	/dʒɔɪnt ˌprɒbəˈbɪləti/	多个事件同时发生的概率，记为P(词1,词2,...,词n)
概率分布	Probability Distribution	/ˌprɒbəˈbɪləti ˌdɪstrɪˈbjuːʃən/	描述随机变量所有可能取值及其概率的函数，语言模型的核心输出对象
香农游戏	Shannon Game	/ˈʃænən geɪm/	香农在1948年提出的根据前文预测下一个字母的思想实验，语言模型概念的雏形
自回归生成	Autoregressive Generation	/ɔːtoʊrɪˈgresɪv ˌdʒenəˈreɪʃən/	从左到右逐词生成文本序列的过程，每一步依赖之前已生成的全部内容
下一Token预测	Next-Token Prediction	/nekst ˈtoʊkən prɪˈdɪkʃən/	语言模型根据已有Token序列预测下一个Token的核心训练任务和目标
信息熵	Entropy	/ˈentrəpi/	衡量信息不确定性的度量单位，香农提出的核心概念