# 语言模型（二）-从数据中学习规律

- 来源: https://class.imooc.com/lesson/5255#mid=104878
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: 语言模型
- 课节: 图文 1-3 语言模型（二）-从数据中学习规律

## 1-3 语言模型（二）-从数据中学习规律

## 语言模型（二）-从数据中学习规律

> [!TIP] 阅读指南 上一节，我们了解了语言模型如何用数学建模语言的概率分布。这些语法规律、语义规律，是人工编程进去的吗？ 本节将揭示规律是如何从海量数据中自动"涌现"出来的。

## 9.1 规律是“学”出来的，不是“编”出来的

这些语法规律、语义规律、上下文规律，是人工编程进去的吗?

不是。完全不是。

没有人告诉ChatGPT“猫不会飞”，没有人告诉它“‘的’不能跟在‘喜欢’后面”，没有人告诉它“‘它’要指代前面的名词”。

这些规律，全部是从数据中自动“浮现”出来的。

训练数据中的模式

在ChatGPT的训练数据（几千亿个词）中，“猫会爬树”可能出现了成百上千次，“猫会飞”几乎从未出现（除非是在童话故事里）。“我喜欢吃”出现了数百万次，“我喜欢的吃”几乎从未出现。

模型通过统计，“学”到了规律

在不断调整那1750亿个参数的过程中，模型逐渐“发现”：在“猫会”后面，“爬树”出现的频率远高于“飞”；在“我喜欢”后面，“吃”出现的频率远高于“的”。

然后，它把这些统计规律编码进参数中。最终，当问它“猫会____”，它会给“爬树”更高的概率。

这是一种深刻的哲学转变

传统的自然语言处理，是语言学家总结语法规则，程序员把规则写成代码，计算机执行这些规则。

而现代的语言模型，是收集海量文本，让模型自己从文本中学习规律，规律自动“浮现”在参数中。

前者是“演绎法”：从规则到应用。后者是“归纳法”：从数据到规律。

ChatGPT的成功，很大程度上证明了在足够大的数据和足够多的参数下，归纳法可以超越演绎法。

## 9.2 为什么归纳法更有效?

这个发现，颠覆了人们对AI的传统认知。

演绎法的局限

传统方法依赖语言学家手动总结规则。但语言太复杂了：语法规则就有成千上万条，而且每条都有例外。比如“我吃饭”符合语法，但“我饭吃”不符合。但“饭我吃完了”又符合了（话题前置）。更不用说网络用语：“今天emo了”、“绝绝子”、“YYDS”……

如果要把所有规则都写进代码，几乎不可能。而且语言还在不断演化，规则永远跟不上变化。

归纳法的优势

语言模型不需要任何人告诉它规则。它只需要做一件事：看足够多的文本，统计规律。

在训练数据中，“我吃饭”出现了500万次，“我饭吃”出现了100次（多半是打字错误），“饭我吃完了”出现了50万次。模型通过统计，自动学会了：“我”后面接“吃”再接“饭”，概率高；“我”后面直接接“饭”再接“吃”，概率低；但如果上下文是“吃完了”，那“饭我吃”的概率就提高了。

不需要任何人告诉它语法规则。它自己从数据中“悟”出来了。

“大力出奇迹”的第一次体现

这里看到了“大力出奇迹”的第一次体现：不是靠精巧的算法设计，而是靠海量的数据加巨大的计算力。

当数据量足够大时，规律会自然浮现。这种思路看似“笨”，但却异常有效。

这也是为什么大模型需要“大”：不够大的话，规律就浮现不出来。

## 9.3 ■ 学点英语

| 中文 | English | 音标 | 说明 |
| --- | --- | --- | --- |
| 归纳法 | Inductive Learning | /ɪnˈdʌktɪv ˈlɜːnɪŋ/ | 从大量具体数据中自动总结规律的方法，现代语言模型的核心范式 |
| 演绎法 | Deductive Reasoning | /dɪˈdʌktɪv ˈriːzənɪŋ/ | 从已有规则出发推导结论的方法，传统编程的语言处理方式 |
| 统计学习 | Statistical Learning | /stəˈtɪstɪkl ˈlɜːnɪŋ/ | 从数据中发现统计模式并将其编码到模型参数中的学习方法 |
| 参数 | Parameter | /pəˈræmɪtər/ | 模型在训练过程中学习到的可调整变量，编码了从数据中学到的知识和规律 |
| 语料库 | Corpus | /ˈkɔːrpəs/ | 用于训练或评估语言模型的大规模文本集合（复数形式：Corpora） |
| 模式识别 | Pattern Recognition | /ˈpætərn ˌrekəgˈnɪʃən/ | 从数据中发现重复出现结构的能力，语言模型通过统计模式识别语言规律 |
| 训练数据 | Training Data | /ˈtreɪnɪŋ ˈdeɪtə/ | 用于训练模型的原始文本集合，是模型学习语言规律的知识来源 |