语言模型（四）-大语言模型与对话系统

- 来源: https://class.imooc.com/lesson/5255#mid=104880
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第1周 语言模型是什么
- 模块: 语言模型
- 课节: 图文 1-7 语言模型（四）-大语言模型与对话系统

1-7 语言模型（四）-大语言模型与对话系统

语言模型（四）-大语言模型与对话系统

> [!TIP] 阅读指南 上一节回顾了语言模型的三代演进史。既然Transformer这么强大，模型需要多大才够用？为什么要搞得那么大？本节将探讨"大"语言模型的规模革命，以及语言模型与对话系统的本质区别。

11.1 "大"语言模型

经常听到"大语言模型"（Large Language Model, LLM）这个词。这个"大"，到底有多大？为什么要这么大？

参数规模的爆炸式增长

一组数字记录了AI领域一场真正的军备竞赛：

GPT系列的参数，从2018年的GPT-1（1.17亿参数）到GPT-3（1750亿参数），仅仅两年时间，参数量就增长了约1500倍。

到2025-2026年，主流大模型已经进入万亿级时代：

> GPT-4o (OpenAI, 2024): ~1.8万亿 参数 GPT-5 (OpenAI, 2025): 约2万亿 参数 Google Gemini 3 (2025): 1万亿 参数 Claude 4 (Anthropic, 2025): 约1.5万亿 参数

训练数据的海量堆积

> GPT-2: 40GB文本 ≈ 80本百万字小说 GPT-3: 570GB文本 ≈ 1140本百万字小说 GPT-4/5: 未公开 (估计更大规模)

为什么需要这么多数据?

语言模型是通过"见识"来学习的。想象要学一门外语，如果只读过10篇文章，能掌握多少？但读过10万篇文章，语感会完全不同。

ChatGPT"读"过的文本，比一个人一辈子能读的多出几万倍。

"大"的哲学意义

这里有一个深刻的发现，也是过去十年AI研究最重要的洞察之一：

在语言模型领域，"大力出奇迹"是真实存在的。

不是线性的"大一点好一点"，而是规模达到某个临界点后，能力突然跃升。

这种现象被称为"涌现能力"，会在第8节详细讲解。那里会深入探讨Scaling Laws（缩放法则）——一个描述模型性能与规模之间数学关系的重要发现。

现在只需要记住：“大"不是虚荣，而是必需。没有这个"大”，就没有ChatGPT的智能。

11.2 大语言模型与小语言模型

"大"的标准是什么？多大才算大？目前行业内没有严格的官方划分，但有一个约定俗成的分界线。

小语言模型（SLM - Small Language Model）

参数量小于100亿（< 10B）。代表模型包括ChatGLM-6B、Mistral-7B、LLaMA-2-7B。这类模型轻量级，可以在个人电脑或手机上运行。

中型语言模型

参数量在100亿到1000亿之间（10B - 100B）。代表模型有LLaMA-2-70B、Qwen-72B。需要多块GPU，但仍能本地部署。

大语言模型（LLM）

参数量大于1000亿（> 100B）。代表模型如GPT-3（175B）、GPT-4（估计万亿级）。需要巨型计算集群，通常只能通过云服务访问。

这个区分很重要，因为它决定了能力边界、部署成本和应用场景。

小模型适合特定领域任务，如文本分类、情感分析。大模型具备通用智能，能处理复杂的推理、创作任务。

小模型几千元的个人电脑就能运行。大模型需要数百万甚至数千万的GPU集群。

小模型适用于移动设备、边缘计算、隐私敏感场景。大模型适用于云服务、复杂任务、通用AI助手。

一个趣味的趋势："小而精"的崛起

近年来，一个有意思的现象出现了。以前的思路是模型越大越好，现在的发现是小模型也可以很强。

例如：

> Mistral-7B（仅70亿参数），能力接近GPT-3.5 ChatGLM-6B，能在个人电脑上运行，效果也不错

这说明：

- "大"不是唯一的路
- 更好的训练方法、数据质量、模型架构同样重要
- 未来可能是"大小共存"：大模型做通用任务，小模型做专用任务

对于现在的ChatGPT来说，它确实是一个"大"语言模型。

11.3 语言模型与对话模型

需要澄清一个容易混淆的概念。

ChatGPT不仅仅是一个语言模型，更是一个对话模型。

关键区分

可能听说过这些名字：GPT-3、GPT-4、GPT-3.5、ChatGPT……它们之间是什么关系？

GPT-1/2/3/4/5（基础语言模型）

> GPT-1 (2018): 1.17亿参数 GPT-2 (2019): 15亿参数 GPT-3 (2020): 1750亿参数 GPT-3.5 (2022): 未公开（GPT-3的优化版） GPT-4 (2023): 未公开 GPT-4o (2024): 未公开 GPT-5 (2025): 未公开

这些是技术名称，指的是基础语言模型。它们只经过预训练，能力是"预测下一个词"。

ChatGPT（对话产品）

ChatGPT 是产品名称，不是模型名称。

> ChatGPT = 基础模型 + 对话训练 例如： ChatGPT（早期）= GPT-3.5 + 对话训练 ChatGPT（后期）= GPT-4 + 对话训练 ChatGPT（最新）= GPT-4o/GPT-5 + 对话训练

使用ChatGPT时，用的不是纯GPT-4，而是经过对话训练的ChatGPT（基于GPT-4）。它会"聊天"而不是简单"接龙"，就是因为有额外的对话训练。

纯粹的语言模型只会"接龙"，不会"对话"

如果直接用GPT-3（纯语言模型），问它：

> “如何学习编程？”

它可能会这样"接龙"：

> “如何学习编程？这个问题很多人问过。首先，你需要明确你的学习目标……”

或者：

> “如何学习编程？我也不知道。我从来没学过编程……”

为什么会这样？

纯语言模型的训练目标，只是"预测下一个词"。它在互联网文本中见过：

- 有文章以"如何学习编程？这个问题……"开头
- 有论坛帖子是"如何学习编程？我也不知道……"
- 有网页列举"如何学习编程？如何学习……"

它只是在"接龙"，把输入当成一篇文章的开头，继续写下去。它不知道你在问问题，也不知道要给出答案。

而对话模型可以理解"问答"这个概念。如果是ChatGPT（对话模型）会这样回应：

> "学习编程可以遵循以下步骤： 选择一门编程语言：对于初学者，推荐Python，因为语法简单易读。 学习基础语法：通过在线教程（如Codecademy、freeCodeCamp）掌握变量、循环、函数等基本概念。 动手实践：做小项目，比如计算器、待办事项列表等，把知识应用到实际中。 阅读他人代码：看GitHub上的优秀项目，学习他人的编程思路。 持续学习：编程是一个不断学习的过程，保持好奇心和练习习惯很重要。 你想从哪门语言开始？"

它理解了你在提问，它知道要给出结构化的建议，它甚至会反问，引导对话继续。

这个差别是怎么来的?

答案是：预训练之后的额外训练步骤。

- 纯语言模型 = 预训练
- 对话模型 = 预训练 + 监督微调（SFT） + 强化学习对齐（RLHF）

后面的章节会详细讲这个过程。现在只需要知道：

ChatGPT的"聊天"能力，不是预训练自然产生的，而是通过额外的训练"教"会的。

这也是为什么ChatGPT比GPT-3好用得多，虽然底层的语言模型可能差不多。

产品化的最后一公里，比技术突破更重要。

11.4 ■ 学点英语

中文	English	音标	说明
大语言模型	Large Language Model (LLM)	/lɑːdʒ ˈlæŋgwɪdʒ ˈmɒdl/	参数量通常在数十亿到数千亿级别的语言模型
涌现能力	Emergent Abilities	/ɪˈmɜːdʒənt əˈbɪlətiz/	模型规模超过某个阈值后突然出现的、小模型不具备的能力
基础模型	Foundation Model	/faʊnˈdeɪʃən ˈmɒdl/	经过大规模预训练的通用语言模型，可作为下游任务微调的基础
监督微调	Supervised Fine-Tuning (SFT)	/ˌsuːpərvaɪzd faɪn ˈtjuːnɪŋ/	使用人工标注的指令-回答数据训练模型理解和遵循人类指令
人类反馈强化学习	Reinforcement Learning from Human Feedback (RLHF)	/ˌriːɪnˈfɔːrsmənt ˈlɜːnɪŋ frəm ˈhjuːmən ˈfiːdbæk/	通过人类偏好评分训练奖励模型，再用强化学习优化模型输出使其符合人类期望
对话模型	Dialogue Model	/ˈdaɪəlɒg ˈmɒdl/	经过指令微调和对齐训练的、能进行多轮对话的语言模型
规模定律	Scaling Laws	/ˈskeɪlɪŋ lɔːz/	描述模型性能随参数、数据、计算量增长而提升的经验规律