扩展练习

- 来源: https://class.imooc.com/lesson/5258#mid=104963
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第2周 语言模型怎么训练
- 模块: 预训练
- 课节: 图文 1-7 扩展练习

1-7 扩展练习

扩展练习

1

题型: 判断题 难度: 中等

题干: Google开源了Gemini（双子座）大模型，所以任何人都可以下载和使用它。(复习题)

正确答案: 错误

解析: Google的策略是"旗舰模型闭源，轻量模型开源"。Gemini是旗舰模型，完全闭源，只能通过API调用。开源的是Gemma（小宝石），基于Gemini技术但参数量小得多。类似Android策略——开源Android操作系统，但Google服务核心是闭源的。

2

题干: Common Crawl是一个非营利组织的免费数据集，几乎所有大模型都使用了它作为训练数据。(复习题)

正确答案: 正确

解析: Common Crawl从2008年开始免费爬取并开放整个互联网的网页数据，目前已包含超过3500亿个网页。GPT-3的60%训练数据、LLaMA的主要数据来源都来自Common Crawl。它解决了数据获取的合法性和标准化问题。

题型: 简答题 难度: 中等

题干: Meta开源LLaMA、阿里开源Qwen、深度求索开源DeepSeek，这些开源行为对AI行业产生了什么影响？你作为开发者能从中获得什么？ (延展题)

参考答案: ○ 降低门槛：小公司和独立开发者不需要花1200万美元做预训练，可以直接在开源模型上微调 ○ 促进创新：开源意味着研究者可以深入分析模型内部、改进算法、发现新方向 ○ 形成生态：开源模型带动了工具链（如llama.cpp）、应用层（如本地部署）的繁荣 ○ 作为开发者：你可以免费下载开源模型做本地部署（数据不外泄）、做领域微调、甚至基于开源模型构建自己的产品。唯一需要的是GPU算力（相比预训练成本，这只是零头）