什么是 好，什么是 不好

- 来源: https://class.imooc.com/lesson/5260#mid=104890
- 阶段: 阶段一：【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: RLHF
- 课节: 图文 1-1 RLHF（一）-什么是对齐

什么是"好"，什么是"不好"

音标

说明

/əˈlaɪnmənt/

让AI系统的行为与人类价值观、意图和期望保持一致

/ˈhelpfl/

对齐三目标之一：真正理解用户意图并提供有用建议

/ˈɒnɪst/

对齐三目标之一：承认不确定、不夸大能力

/ˈhɑːmləs/

对齐三目标之一：拒绝有害请求、避免偏见

/ˌriːɪnˈfɔːsmənt ˈlɜːnɪŋ frəm ˈhjuːmən ˈfiːdbæk/

利用人类偏好数据训练语言模型的技术范式

/ˈsuːpəvaɪzd faɪn ˈtjuːnɪŋ/

用人工标注的问答对训练模型学会指令跟随

/ˈprefrəns/

两个候选中"哪个更好"的相对判断

/ˈvæljuːz/

判断"好"与"坏"的内在标准，难以枚举定义