音标

- 来源: https://class.imooc.com/lesson/5260#mid=104892
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: RLHF
- 课节: 图文 1-7 RLHF（三）-RLHF的局限与思考

音标

说明

/sɪˈkɒfənsi/

模型倾向于说让用户舒服的话而非正确的话

/ˈdʒeɪlbreɪk/

通过提示技巧绕过AI安全限制的行为

/ˌkɒnstɪˈtjuːʃənl eɪ aɪ/

Anthropic提出的基于原则清单进行自我改进的对齐方法

/ɪnˌtɜːprətəˈbɪləti/

让模型的决策理由对人类可理解、可审查

/blæk bɒks/

内部机制不可见、只知输入输出的系统

/edʒ keɪs/

处于正常范围之外、容易触发异常行为的罕见输入

/kənˈtɪnjuəl ˈlɜːnɪŋ/

模型随时间推移不断吸收新数据与新偏好的能力

/ˈtrɒli ˈprɒbləm/

经典伦理思想实验，常被用于讨论AI的道德权衡