第3章 第4节 涌现能力（一）-令人震撼的发现

- 来源: https://class.imooc.com/lesson/5261#mid=104893
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: 涌现能力
- 课节: 图文 1-1 涌现能力（一）-令人震撼的发现

1-1 涌现能力（一）-令人震撼的发现

第3章 第4节 涌现能力（一）-令人震撼的发现

> [!TIP] 阅读指南 前面七节，我们深入了解了ChatGPT是如何一步步被"教"出来的：预训练教会了它语言，监督微调教会了它任务，RLHF教会了它价值观。 现在，一个更加神秘、更加令人惊叹的现象出现了——一个连研究者们自己都没完全想到的现象。 当语言模型的规模达到一定程度时，它会突然展现出一些从未被明确"教过"的能力。 这就像是，教一个孩子识字、阅读、理解句子，然后有一天，突然发现他学会了写诗——虽然从未教过他"如何写诗"，但这个能力自己"涌现"出来了。 这种现象，在AI领域被称为"涌现能力"(Emergent Abilities)或"涌现现象"(Emergence)。 上篇通过具体的例子，让你直观感受什么是涌现能力，以及它有多么震撼。 中篇将探讨"为什么会涌现"以及Scaling Laws。 下篇将讨论涌现的局限性和哲学思考。

4.1 从一个具体例子开始

在正式定义之前，先用一个具体的例子，建立直觉。

GPT-3之前的模型：不会算术

早期的语言模型（比如GPT-2，1.5亿参数），如果你问它：

> 问题： “23 + 47 = ?” GPT-2的回答: “23 + 47 = 60” ← 错误!(正确答案是70) 或者: “23 + 47 = 70” ← 偶尔对 "23 + 47 = 69" ← 但大多数时候错

准确率大约只有5-10%,基本上是在"瞎猜"。

GPT-3 （1750亿参数）：突然会算了

但当模型规模扩大到GPT-3时，同样的问题：

> 问题：“23 + 47 = ?” GPT-3的回答：“70” ← 正确!

GPT-3的回答：“70” ← 正确!

准确率跃升到80-90%。

关键的问题是：没有人教过GPT-3如何做加法。

没有人教过GPT-3如何做加法。

训练数据中，确实包含了很多涉及数字和计算的文本:

> “总共花费23美元加上47美元的税，等于70美元” “23个苹果加上47个苹果，一共有70个苹果” …

但这些只是自然语言文本，没有人明确告诉模型：“这是加法，你应该学会计算”。

模型只是在做它一直在做的事：预测下一个词。

预测下一个词

然而，当模型规模足够大时，它从这些文本模式中，自己"悟"出了加法的规律。

这，就是涌现。

4.2 什么是涌现能力

现在，让我给出一个更正式的定义。

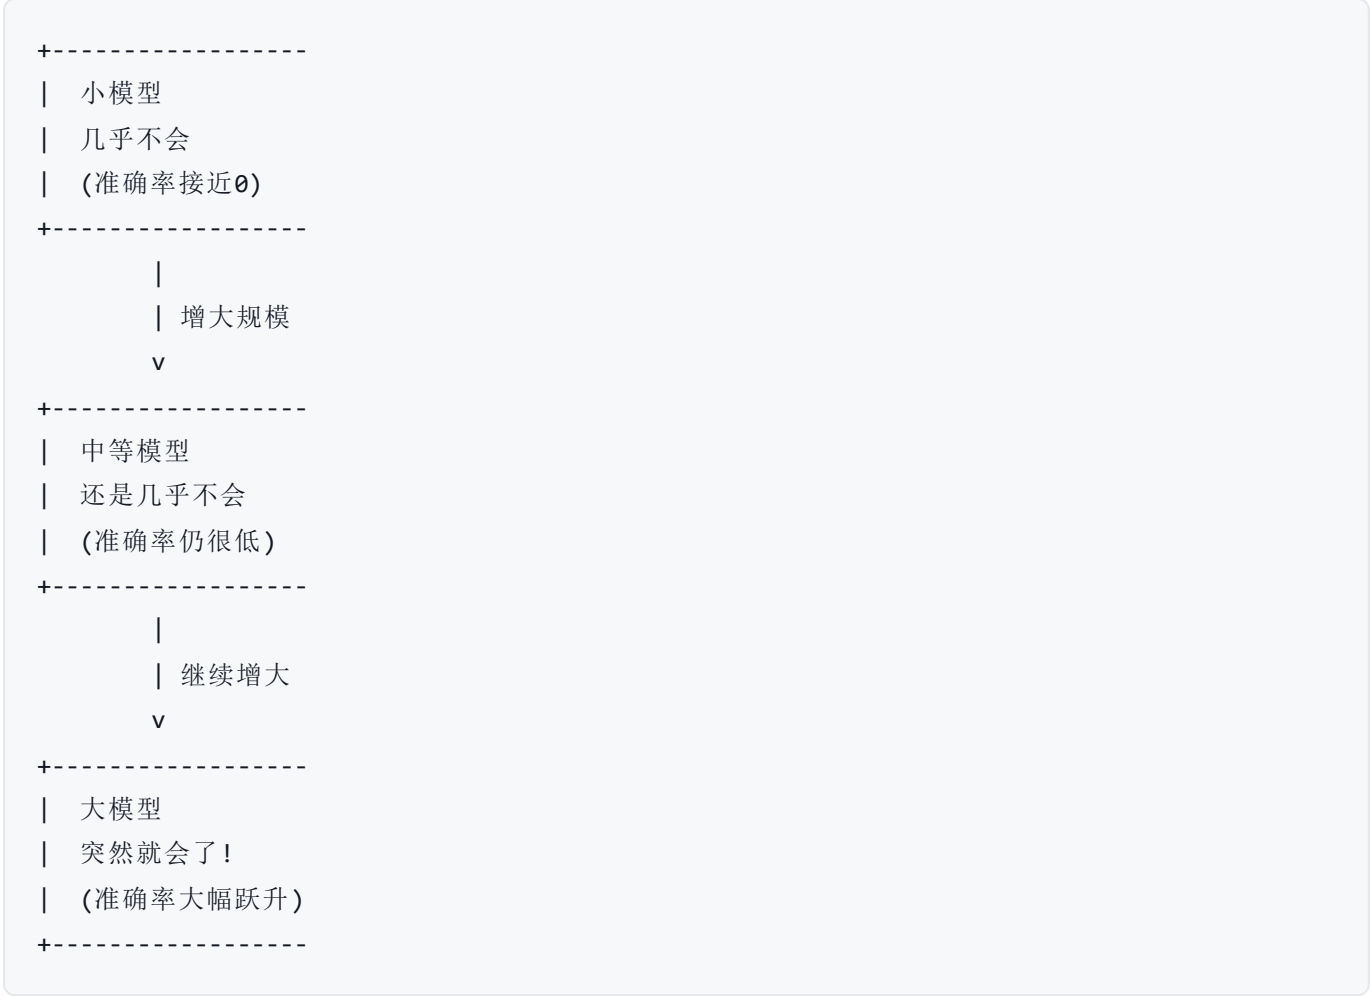
涌现能力(Emergent Abilities)：

> 当模型规模超过某个阈值时，突然出现的、在小规模模型中几乎不存在的能力。

这个定义有几个关键点：

关键点1：突然性

不是线性增长，而是跃迁式的。



关键点2：未被明确训练

这些能力不是通过"专门训练"获得的，而是从通用的语言建模任务中"涌现"出来的。

关键点3：规模依赖

必须达到一定规模，才会出现。小模型无论怎么训练，都不会有这些能力。

让我用一个物理学的类比:

> 水的状态: 0°C以上：液态 0°C:突然变成固态(冰) 这个转变是突然的，不是渐进的。 你不会说"半液态半固态"。 温度(类比模型规模)达到某个阈值， 整个系统的性质发生质变。

涌现能力，就像水的相变。

4.3 令人震撼的发现

2022年，Google的研究团队发表了一篇题为《Emergent Abilities of Large Language Models》的论文，系统地研究了大语言模型的涌现能力。

他们发现，至少有几十种能力表现出了明显的涌现特征。其中有几个最令人印象深刻的例子。

算术推理

我们刚才已经看到了简单加法的例子。但涌现的不仅仅是加法，还有更复杂的数学推理。

例子：多步算术

> 问题： “小明有23个苹果，他给了小红7个，然后又买了15个。小明现在有多少个苹果?” 需要的步骤: 23 - 7 = 16 16 + 15 = 31 GPT-2 (1.5亿参数): 回答： “小明有很多苹果” ← 完全不会 GPT-3 (1750亿参数): 回答： “31个” ← 正确!

例子：百分比计算

> 问题： “如果一件商品原价100元，打八折，再减10元，最后价格是多少?” 需要: 100 × 0.8 = 80 80 - 10 = 70 GPT-3能够正确回答：70元

逻辑推理

例子：三段论推理

> 前提1：所有的猫都是哺乳动物 前提2：Tom是一只猫 问题：Tom是哺乳动物吗? 小模型: 可能回答:“Tom是一个名字” 或 “猫很可爱” ← 答非所问 大模型: 回答： “是的，Tom是哺乳动物。因为所有猫都是哺乳动物，而Tom是猫， 所以Tom也是哺乳动物。” ← 完整的逻辑链条

例子：反事实推理

> 问题： “如果拿破仑在滑铁卢战役中获胜，欧洲历史会如何不同?” 小模型: “拿破仑是法国皇帝。...” ← 只是陈述事实 大模型: “如果拿破仑获胜，法国可能会保持其在欧洲的主导地位，维也纳体系 可能不会形成，欧洲的君主制复辟可能会被推迟。...” ← 进行反事实推理

代码理解和生成

这可能是最令人惊讶的涌现能力之一。

记住:GPT-3的训练目标只是"预测下一个词",没有人教它"编程"。

但是:

> 问题： “用Python写一个函数，检查一个数是否是质数” GPT-3的回答: def is_prime(n): if n < 2: return False for i in range(2, int(n ** 0.5) + 1): if n % i == 0: return False return True ← 完全正确的代码!

更令人惊讶的是，它还能:

理解代码

> 给它一段代码: def mystery(n): if n <= 1: return n return mystery(n-1) + mystery(n-2) 问: “这个函数做什么?” GPT-3:"这是一个计算斐波那契数列的递归函数。" ← 正确理解了代码逻辑!

修复代码错误

> 给它一段有bug的代码，它能指出错误并修正。

语言翻译（对于低资源语言）

这个更微妙，但同样惊人。

GPT-3的训练数据主要是英语(93%),其他语言占比很小。对于某些"低资源语言"(如孟加拉语),训练数据极少。

但GPT-3仍然能够:

> 英语 → 孟加拉语 的翻译 即使训练数据中这种翻译对极少 它似乎学会了: 英语的语义 孟加拉语的语法 如何在两者之间建立映射 这三个能力组合起来，产生了"翻译"这个涌现能力

常识推理

例子:物理常识

> 问题： “如果你把一个玻璃杯从桌子上推下去，会发生什么?” 小模型: “玻璃杯会移动” ← 技术上正确，但太肤浅 大模型: "玻璃杯会掉到地上，由于玻璃很脆，很可能会摔碎。" ← 展现了对重力、物体易碎性的理解

例子:社会常识

> 问题： “如果你在电影院大声说话，会怎么样?” 大模型: "其他观众可能会感到不满或要求你安静，因为这会打扰他们观影。 在某些情况下，工作人员可能会要求你离开。" ← 理解社会规范和后果

多步骤任务规划

> 问题： “我想学习机器学习，但我只有高中数学基础。请给我一个6个月的学习计划。” 大模型能够: 评估现状(高中数学) 识别差距(需要线性代数、微积分、概率论) 规划阶段: 第1-2月:补数学基础 第3-4月:学习Python和基础算法 第4-5月:学习机器学习基础 第6月:做项目巩固 提供具体资源 这种多步骤、有层次的规划能力，是涌现的。

4.4 下节预告

上篇让你直观感受了涌现能力的震撼，但你可能有疑问：

> 为什么会涌现？ 是魔法吗？还是有什么科学原理？ 如果我们能理解"为什么"，能不能更好地利用它?

中篇将深入探讨涌现的机制，揭示4个理论假说，以及一个让整个AI界疯狂的数学定律——Scaling Laws。

4.5 ■ 学点英语

中文	English	音标	说明
涌现能力	Emergent Abilities	/ɪˈmɜːdʒənt əˈbɪlətiz/	模型规模跨过某阈值时突然出现的、在小模型中几乎不存在的能力
涌现	Emergence	/ɪˈmɜːdʒəns/	整体展现出局部不具备的性质，跨层级的新特性
阈值	Threshold	/ˈθreʃhəʊld/	触发质变的临界点，规模跨过后能力跃迁
相变	Phase Transition	/feɪz trænˈzɪʃn/	物理学术语，比喻涌现的非线性跃迁特征
算术推理	Arithmetic Reasoning	/əˈrɪθmətɪkˈriːzənɪŋ/	模型执行加减乘除与多步计算的能力
反事实推理	Counterfactual Reasoning	/ˌkaʊntəˈfæktʃuəlˈriːzənɪŋ/	"如果……会怎样"的假设性推理
三段论	Syllogism	/ˈsɪlədʒɪzəm/	由大前提、小前提和结论组成的逻辑推理形式
低资源语言	Low-resource Language	/ləʊ rɪˈsɔːrsˈlæŋgwɪdʒ/	训练语料稀少的小语种，如孟加拉语
递归函数	Recursive Function	/rɪˈkɜːrsɪv ˈfʌŋkʃn/	在自身定义中调用自身的函数，如斐波那契数列