第3章 第5节 涌现能力（二）-为什么会涌现

- 来源: https://class.imooc.com/lesson/5261#mid=104894
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: 涌现能力
- 课节: 图文 1-4 涌现能力（二）-为什么会涌现

1-4 涌现能力（二）-为什么会涌现

第3章 第5节 涌现能力（二）-为什么会涌现

> [!TIP] 阅读指南 上篇通过具体的例子，让你直观感受了涌现能力的震撼：算术、逻辑推理、代码生成、翻译、常识推理等能力，在大模型中"突然出现"。 中篇将深入探讨： 涌现的机制：为什么会产生涌现？ Scaling Laws：一个让"赌"涌现变得可预测的数学定律 这对AI发展意味着什么？ 下篇将讨论涌现的局限性、不可预测性，以及哲学思考。

5.1 涌现曲线

研究者们绘制了能力与模型规模的曲线，发现了一个惊人的模式。

上图表明:**

> 存在阈值: 算术能力:大约在130亿参数左右涌现 复杂推理:大约在500-1000亿参数涌现 代码能力:大约在100-300亿参数涌现 不同能力的阈值不同: 简单任务先涌现，复杂任务后涌现 涌现是突然的: 不是平滑增长，而是有一个"拐点"

5.2 为什么会涌现

这是最令人着迷，也最令人不安的部分：我们不完全理解涌现为什么发生。

有几个理论假说:

假说1:隐式学习组合能力

模型学到了很多"原子能力",当规模够大时，这些能力可以组合起来，产生新的"复合能力"。

> 例子:算术能力的涌现 模型可能分别学到了: 能力A:识别数字符号 能力B:理解"加"这个词的语义 能力C:数字大小的概念 能力D:数值操作的模式 小模型:每个能力都很弱，无法组合 大模型:每个能力都够强，可以组合 → 涌现出"算术"

假说2:跨越理解阈值

某些任务需要对概念有"足够深"的理解，达不到这个深度，就完全做不了。

> 例子:逻辑推理 需要: 理解"所有"的含义(全称量词) 理解"因为。...所以。..."的逻辑关系 追踪多个命题之间的关系 如果理解深度只有50%: 可能看起来"理解了",但推理时就错 如果理解深度达到85%: 突然能够正确推理了 这个"85%"就是阈值

小模型达不到阈值，大模型跨越了阈值，所以能力"涌现"。

假说3:记忆容量达到临界点

某些任务需要记住很多模式和例子，当记忆容量不够时，完全学不会。

> 例子:代码生成 训练数据中有数百万个代码片段，涵盖: 各种编程范式 各种语法结构 各种算法模式 ... 小模型:记忆容量有限，只能记住一小部分模式 → 遇到新问题，无法找到合适的模式 → 失败 大模型:记忆容量大，能记住大部分模式 → 遇到新问题，能找到相似的模式并适配 → 成功

假说4:涌现可能是幻觉

一些研究者认为，"涌现"可能部分是我们"测量方式"造成的幻觉。

> 论点: 如果我们用"准确率"(0或1)来衡量，会看到"突然涌现" 如果我们用更细粒度的指标(比如"部分正确度"),可能看到的是平滑增长 例子: 小模型: “23 + 47 = 60” ← 准确率0%,但其实已经学到了"加法"的概念，只是算错了 大模型: “23 + 47 = 70” ← 准确率100% 如果用"是否理解加法的概念"来衡量，小模型可能已经部分理解了， 而不是"完全不会" → “突然会了”

这个观点有一定道理，但不能完全解释所有的涌现现象。

但真相可能是以上几个因素的综合:

- 某些能力确实是组合的
- 某些任务确实有理解阈值
- 某些涌现可能被我们的测量方式夸大了

无论原因是什么，大模型确实展现出了小模型没有的能力。

5.3 涌现的启示

涌现现象给了我们一个深刻的启示:

在深度学习中，规模不仅仅带来量的提升，还可能带来质的飞跃。

这被研究者们半开玩笑地总结为:大力出奇迹。这意味着什么?

启示1:不要低估规模的力量

> 传统思维: “如果小模型做不好某个任务，那可能这个任务不适合这种方法” 涌现思维: “如果小模型做不好，可能只是模型还不够大。 继续扩大，可能会突然就做好了。”

启示2:能力可能"潜伏"在小模型中

> 小模型可能已经学到了某个能力的"雏形", 只是还不足以表现出来。 当规模增大，这些"雏形"成熟了，能力就涌现了。

启示3:我们可能还没有触及"天花板"

> GPT-3 (1750亿参数)涌现了很多能力 GPT-4 (参数未公开，可能5000-10000亿)涌现了更多能力 如果继续扩大到1万亿、10万亿参数， 可能还会涌现出我们现在完全想不到的能力。

但这也带来了一个问题。

5.4 令人不安的一面

涌现能力虽然令人惊叹，但也带来了一个问题:

我们无法预测哪些能力会涌现。

在训练GPT-3之前，OpenAI的研究者们并不知道它会涌现出算术能力、代码能力、多语言翻译能力。...

这些能力的出现，是惊喜，但也可能是惊吓。

- 好的能力会涌现，坏的能力也可能涌现

> 好的涌现: 算术推理 代码生成 逻辑推理 坏的涌现可能: 生成更有说服力的虚假信息 学会欺骗(在某些情况下) 发现系统的安全漏洞并利用

- 我们无法提前测试

因为涌现是突然的，我们无法在小模型上"预见"大模型会有什么能力。

如果训练一个超大模型，在训练完成之前，我们不知道它会涌现出什么能力。

- 对齐变得更困难

我们在RLHF中对齐的，是我们"已知"的能力和行为。

但如果模型涌现出新的能力，这些能力可能没有被充分对齐。

GPT-3训练完成后，研究者们发现它能生成代码。但RLHF主要针对的是回答问题、拒绝有害请求等。对于生成代码的行为规范，可能没有充分对齐。

这是AI安全研究的一个核心关切。

5.5 Scaling Laws

虽然我们不能预测哪些能力会在什么时候涌现，但研究者们发现，模型的性能与规模之间，存在某种数学关系。

这被称为"Scaling Laws"(缩放法则)。什么是Scaling Laws?

Scaling Laws，直译是"扩展定律"或"缩放定律"，指的是：当你改变系统的规模时，性能如何变化的规律。

在AI的语境里，具体指:

- Scaling = 扩大规模（更多参数、更多数据、更多算力）
- Laws = 定律（可预测的数学关系）

简单说：Scaling Laws告诉我们，模型越大，效果会按照什么规律变好。

Scaling Laws告诉我们，模型越大，效果会按照什么规律变好。

2020年，OpenAI的研究人员发表了一篇论文，震动了整个AI界。

他们发现:模型性能与规模之间，存在可预测的数学关系。

模型性能与规模之间，存在可预测的数学关系

这不是说"模型大一点，性能好一点"这种模糊的直觉，而是一个精确的幂律公式:

幂律

$L(N) \propto N - \alpha$ L(N)∝N −α

−α

∝

N

在此之前，大家都知道"模型越大，效果越好",但不知道:

- 大多少才有用?
- 效果会好多少?
- 值不值得投入更多资源?

而Scaling Laws给出了答案:性能提升是可以预测的。

让我给你一些直观的数字:

> 参数量增加10倍 → Loss降低约1.2倍 参数量增加100倍 → Loss降低约2.0倍 参数量增加1000倍 → Loss降低约3.4倍

这意味着:

- 投入越来越大(参数量成倍增长)
- 但收益越来越小(Loss的绝对下降量递减)

既然收益越来越小，为什么还要继续耗费巨资增加参数量?

答案是人们期待大模型有新的能力能够涌现。

但还是有问题。

我们之前讨论过，涌现是不可预知的，那这样投入是否值得?

Scaling Laws给出了答案。

它的价值在于，让这个对能力涌现的赌注变得安全了:

> 可预测的部分: Loss会按照公式稳定下降 → 即使不涌现，性能也会提升(只是提升有限) 不可预测的部分: 某个Loss阈值可能触发涌现 → 一旦涌现，能力会质变飞跃 而历史数据显示，Loss降到某些关键点时，涌现现象反复出现。

Scaling Laws不能保证涌现，但能保证你在朝着涌现的方向前进。用对比说明:

> 在Scaling Laws之前(2020年前): “我想造个更大的模型” “会更好吗?” → 不知道 "好多少?" → 不知道 "值得投入吗?" → 不知道

这是纯粹的赌博

> 在Scaling Laws之后(2020年后): “我想把模型扩大100倍” “会更好吗?” → 确定会，Loss会降低2倍 "会涌现新能力吗?" → 不确定，但历史上都发生了 "最坏情况?" → Loss降2倍，性能稳定提升 "最好情况?" → 触发涌现，能力质变

这是有保底的风险投资

这就是为什么OpenAI敢"赌"GPT-3:

> 根据Scaling Laws计算: GPT-3的Loss会比GPT-2降低约30% 保底收益:性能稳定提升30% 期望收益:可能触发涌现(基于GPT-2的观察) 实际结果:不仅性能提升了，还涌现了代码、算术等能力

他们赌的不是"会不会涌现",而是"Loss降低后，涌现的概率有多大"。

这就是为什么从2018到2023，我们看到了GPT参数量在疯狂增长:

> 2018年 GPT-1: 117M参数 (基准线) 2019年 GPT-2: 1.5B参数 ← 增长13倍 2020年 GPT-3: 175B参数 ← 增长117倍 2023年 GPT-4: 未公开 ← 规模进一步增长 2025年 GPT-5: 未公开 ← 已发布

每一步，都是对Scaling Laws的验证。每一步，都带来了能力的跃升。

这个Scaling Law会一直有效吗？还是在某个点会失效？

如果一直有效:

那么理论上，只要资源足够，我们就能造出越来越强大的AI，直到…… 直到什么？AGI(通用人工智能)？超越人类的智能？

如果会失效:

失效点在哪里？是因为数据不够了？还是因为这个范式本身到达了极限？

目前没人知道答案。

我们只能观察、实验，然后谨慎地向前。

但有一点是确定的:Scaling Laws给了整个AI领域一个清晰的方向——让模型变大，是一条可预测、可验证的通往更强智能的道路。

5.6 下节预告

Scaling Laws告诉了我们"让模型变大会怎样"，但它没有回答一个问题：

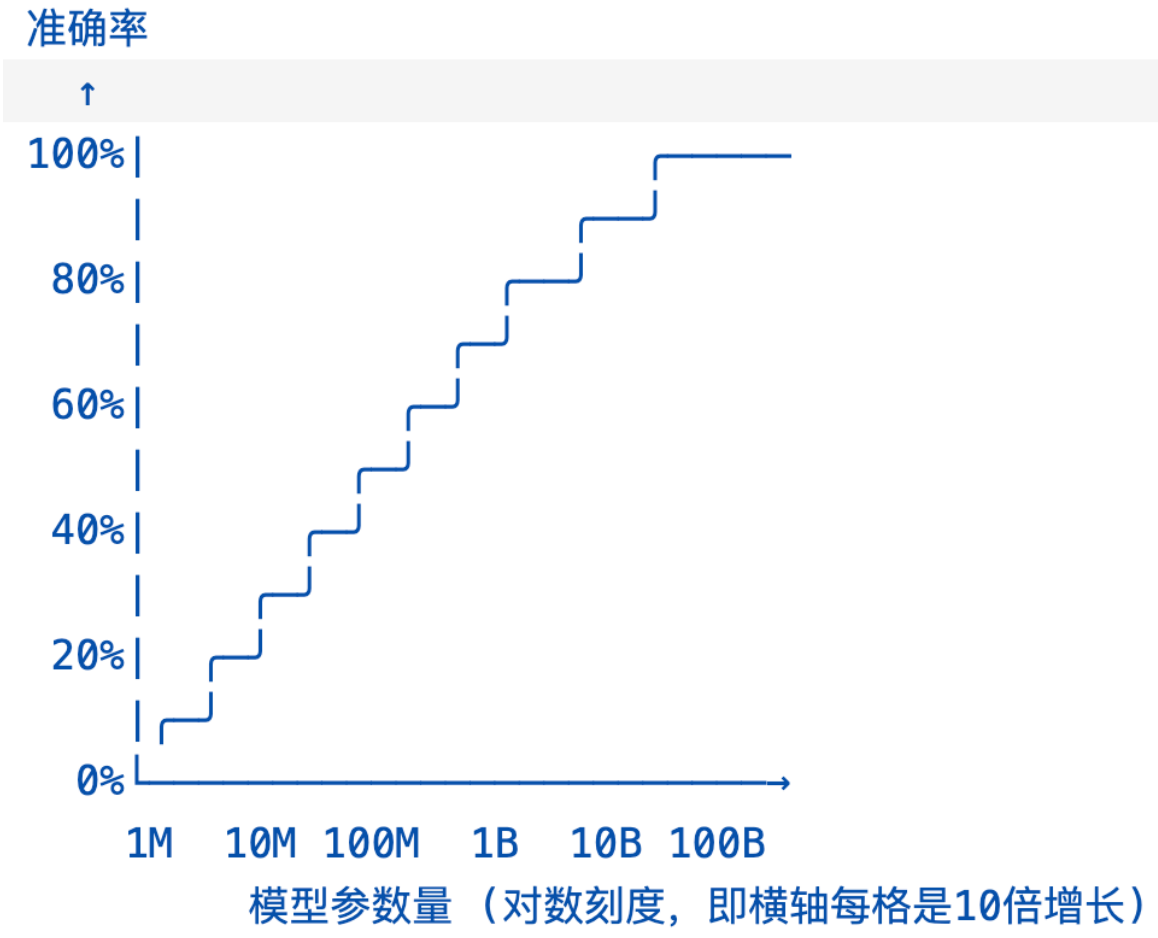
> 是不是所有能力都会通过扩大规模涌现出来？ 有没有什么能力是永远无法涌现的？ 涌现的边界在哪里？

下篇将探讨涌现的边界，以及一些有趣的背后故事。

5.7 ■ 学点英语

中文	English	音标	说明
规模法则	Scaling Laws	/ˈskeɪlɪŋ lɔːz/	模型性能与规模之间的幂律关系规律
幂律	Power Law	/ˈpaʊə® lɔː/	两个变量间成幂指数关系的函数形式
参数量	Parameter Count	/pəˈræmɪtə® kaʊnt/	模型中可学习权重的总数，衡量模型规模
算力	Compute	/kəmˈpjuːt/	训练所消耗的浮点运算量，通常以 FLOPs 计
损失	Loss	/lɒs/	模型预测与真实值之间的误差度量
非线性	Non-linearity	/ˌnɒn lɪnɪˈærəti/	输入与输出不成比例变化的关系，是涌现的数学特征
拐点	Inflection Point	/ɪnˈflekʃn pɔɪnt/	曲线凹凸性转变之处，能力跃迁常在此发生
外推	Extrapolation	/ɪkˌstræpəˈleɪʃn/	从已知范围向外预测未知范围的推理

图片


准确率
↑
100%
80%
60%
40%
20%
0%
1M
10M
100M
1B
10B
100B
模型参数量（对数刻度，即横轴每格是10倍增长）