第3章 第10节 Top-p（二）-核采样的动态控制

- 来源: https://class.imooc.com/lesson/5263#mid=104899
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: Temperature-控制创造力的旋钮
- 课节: 图文 1-4 Top-p（二）-核采样的动态控制

1-4 Top-p（二）-核采样的动态控制

第3章 第10节 Top-p（二）-核采样的动态控制

> [!TIP] 阅读指南 上一节我们学习了Temperature如何通过调整概率分布控制AI的创造力。本节将探讨另一种控制采样的方法——Top-p（核采样），以及它与Temperature的关键区别。

10.1 Top-p（Nucleus Sampling）：另一种控制采样的方法

Temperature不是唯一控制大模型输出风格的手段。

Top-p的核心思想

Top-p和Temperature不同，它不是调整整个概率分布，而是只从"累积概率达到p"的词中采样。

听起来抽象?

假设模型给出了这样的概率分布：

```
词       概率       累积概率
    ──────────────────────────────
     真好      35%        35%
     不错      25%        60%
     很好      20%        80%
     还行      10%        90%  ← 达到Top-p=0.9的阈值
     一般       5%        95%
     糟糕       3%        98%
    ...其他     2%       100%
```

Top-p = 0.9时：

步骤1：按概率从高到低排序（已经排好了）

步骤2：累加概率，直到达到0.9（90%）

> 真好 35% → 累积35% 不错 25% → 累积60% 很好 20% → 累积80% 还行 10% → 累积90% ← 达到90%，停止

步骤3：只从这4个词中采样

> 候选集：【真好、不错、很好、还行】

步骤4：在这4个词中，按原始概率采样（会重新归一化概率，使它们的概率加起来等于1）

Top-p = 0.5时：

只取累积概率到50%的词：

> 真好 35% → 累积35% 不错 25% → 累积60% ← 超过50%了

实际候选集：【真好、不错】

具体以实现为准：有的实现只保留达到阈值前的词"真好"，有的实现会连同刚越过阈值的词"不错"一起保留。

Top-p = 1.0时：

> 取所有词（等于没限制）

Top-p vs Temperature：有什么不同?

这两个方法都控制采样，但方式不同：

① Temperature：

Temperature调整所有词的概率，低温时强化高概率词、压制低概率词，高温时拉平概率分布。

② Top-p：

Top-p只选择"头部"的词，低p值时只考虑最可能的几个词，高p值时考虑更多词。

10.2 关键区别在于动态性

Temperature：固定地调整分布。

> → 不管概率分布情况，调整方式都一样

Top-p：动态地选择候选集

> → 如果模型很确定：候选集小 → 如果模型不确定：候选集大

例子：

情况1：模型很确定

> "这部电影___" 很好 90% ← 模型非常确定 不错 5% 其他 5% Top-p=0.9：只考虑"很好"（因90%就达到阈值了）

情况2：模型不确定

> "未来科技会___" 发展 15% ← 模型不太确定 进步 12% 突破 11% ...很多词概率都差不多 Top-p=0.9：会考虑前10多个词（因为需要很多词才能累积到90%）

这种"动态性"是Top-p的优势：当模型确定时保持确定性，当模型不确定时允许探索。

10.3 Top-p的典型值

p = 0.1：极度保守

> 只考虑最顶端的词 效果接近Temperature=0

p = 0.9：常用平衡点

> ChatGPT的常见默认值 保留大部分合理选项 过滤掉很不可能的词

p = 0.95-1.0：更多创造力

> 考虑几乎所有词 但仍过滤掉极不可能的词（如果p<1）

10.4 Temperature和Top-p可以同时使用吗?

实际上，很多系统（GPT5、Qwen、DeepSeek）的API都允许同时设置两者。

那么当他们同时使用时，Temperature与Top-p执行顺序是怎样的？具体来说，Temperature在Top-p之前执行吗？还是Top-p在Temperature之前执行？

以下是执行步骤：

- 计算原始概率分布
- 应用Temperature调整分布
- 应用Top-p筛选候选集
- 从候选集中采样

可以看到Temperature的调整是在Top-p前面。

> [!TIP] 确实可以同时使用Temperature和Top-p，但OpenAI的建议："一般只调一个，要么Temperature要么Top-p，不建议同时调"

10.5 下节预告

下一节，我们将探讨一个深刻的问题：为什么AI需要随机性？以及不同任务的最佳参数设置建议。

10.6 ■ 学点英语

中文	English	音标	说明
核采样	Nucleus Sampling	/ˈnjuːkliəs ˈsɑːmplɪŋ/	从累计概率达到 p 的动态“核”中采样的解码策略（Top-p）
阈值	Threshold	/ˈθreʃhəʊld/	触发某种行为或满足某种条件的临界值
累积概率	Cumulative Probability	/ˈkjuːmjələtɪv ˌprɒbəˈbɪləti/	按顺序叠加的概率和
候选集	Candidate Set	/ˈkændɪdət set/	采样时实际进入随机选择的词的集合
归一化	Renormalize	/ˌriːˈnɔːməlaɪz/	对筛选后的候选词概率重新调整使其和为 1
不可靠尾部	Unreliable Tail	/ʌnrɪˈlaɪəbl teɪl/	概率分布的低概率区域，容易产生乱码或不相干词
解码策略	Decoding Strategy	/diːˈkəʊdɪŋ ˈstrætədʒi/	从模型概率分布生成最终 Token 序列的方法
光束搜索	Beam Search	/biːm sɜːtʃ/	同时保留多条候选路径的最大化解码方法