1

- 来源: https://class.imooc.com/lesson/5263#mid=104988
- 阶段: 阶段一: 【认知基石】理解大模型的本质与工作原理
- 周: 第3周 语言模型的进阶能力
- 模块: Temperature-控制创造力的旋钮
- 课节: 图文 1-6 扩展练习（2）

1-6 扩展练习（2）

1

题型: 判断题 难度: 中等

题干: 当 Top-p 设置为 1.0 时，等价于"不进行任何 Top-p 过滤"，会保留模型的完整概率分布用于采样。（复习题）

正确答案: 正确

解析: p=1.0 意味着要求累积概率达到 100%，而所有词的概率和本来就是 1.0，所以所有词都被纳入候选集——这等于没有过滤。这也是为什么在实际调用中想"关掉 Top-p 过滤"时，常把它设为 1.0 的原因。相应地，p=0.1 则是极端保守，只留最顶端那少数几个词，效果接近贪心解码。理解 p 的两个端点，有助于把 Top-p 放在一个连续的"过滤强度轴"上去调参。

2

题型: 简答题 难度: 困难

题干: OpenAI 官方建议"Temperature 和 Top-p 一般只调一个，不建议同时调整"。请从采样机制和工程可解释性两个角度，分析这条建议背后的道理。另外，试着举一个例外场景——在什么情况下，同时精细调整两者反而是合理的？（思维题）

参考答案:

● 采样机制角度：两者都改变"下一个 Token 的采样概率"。Temperature 先改变分布形状，Top-p 再截断尾部。如果两者同时变动，最终采样行为是它们的复合效应，很难从外部观察到"究竟是哪一个参数造成了某种输出风格"——这让调参从"单因素实验"退化成"多因素盲调" ● 工程可解释性角度：当线上出现输出异常（太发散、太保守、出现乱码词），如果只调一个参数，问题定位简单；如果两者都在

动，排查成本指数级上升——这在生产环境是一种调试灾难 ● 例外场景：当对输出质量有苛刻要求且有完整离线评测集时，可以做"参数矩阵扫描"——例如系统 Prompt 固定、对 T × Top-p 的二维网格做交叉测试，为每一类业务场景找到最优组合。这种做法只适合有数据闭环、能量化评测的团队 ● 更激进的用法是把 Top-p 设得略小（过滤掉长尾垃圾），同时把 Temperature 略大（在"核"内保留创造性），让输出同时拥有"不跑飞"和"有新意"两种属性——这是经验工程师的常见套路 ● 核心判断：建议是给新手的"避免混乱"原则；例外是给有评测体系的老手的"组合优势"策略。两者并不矛盾

3

题型: 阅读理解题 难度: 困难

题干: Read the following passage and answer the questions below. (延展题)

阅读材料:

> In 2019, Holtzman, Buys, Du, Forbes and Choi published “The Curious Case of Neural Text Degeneration” (ICLR 2020), in which they proposed Nucleus Sampling — the decoding strategy now widely known as Top-p. The paper states: “Despite considerable advances in neural language modeling, it remains an open question what the best decoding strategy is for text generation from a language model… We show that maximization-based decoding methods such as beam search lead to degeneration — output text that is bland, incoherent, or gets stuck in repetitive loops. To address this issue, we propose Nucleus Sampling, a simple but effective method to draw considerably higher quality text out of neural language models than previous decoding strategies. Our approach avoids text degeneration by truncating the unreliable tail of the probability distribution, sampling from the dynamic nucleus of tokens containing the vast majority of the probability mass.”

题目1:

题型: 单选题

题干: According to the passage, which of the following best summarizes the central motivation for proposing Nucleus Sampling?

选项A: Maximization-based decoding methods like beam search always produce the most diverse and high-quality text. 选项B: Pure random sampling over the full vocabulary is the only way to avoid repetition in generated text. 选项C: Maximization-based decoding tends to produce bland, incoherent or repetitive text, and a better strategy is to sample from a dynamic

“nucleus” of high-probability tokens while truncating the unreliable low-probability tail. 选项D: The best decoding strategy is to train larger models; decoding choices have little effect on output quality.

正确答案: C

解析: 原文明确提到 beam search 等 maximization-based decoding 会造成 degeneration（退化）——“bland, incoherent, or gets stuck in repetitive loops”，而 Nucleus Sampling 的核心思路是"truncate the unreliable tail"并从"dynamic nucleus"中采样，选项C 的概括与原文一一对应。选项A 直接与原文矛盾；选项B 是极端相反的"纯随机"方向，也不是本文的提案；选项D 把问题甩锅给模型规模，与论文聚焦解码策略的定位不符。

题目2:

题型: 判断题

题干: The phrase “dynamic nucleus” in the passage implies that the size of the candidate token set adapts to the shape of the probability distribution at each step, rather than being fixed in advance.

解析: “Dynamic nucleus"是 Nucleus Sampling 这个名字的精髓：nucleus（核）的大小不是预先固定的 k 个词（那是 Top-k），而是在每一步根据概率分布的形状动态调整——分布尖锐时核小，分布平坦时核大。这个特性也正是 Top-p 相较 Top-k 的根本优势：它用"累积概率"这个与分布形状相关的度量来定义候选集，而不是用"硬数量”。理解了这一点，也就理解了为什么在遇到"模型不确定的位置"时 Top-p 能保留更多探索空间、在"模型确定的位置"又能自动收紧。