第4章 第7节 流式输出与长度控制

- 来源: https://class.imooc.com/lesson/5269#mid=104908
- 阶段: 阶段二: 【实战入门】大模型开发与知识接入
- 周: 第4周 理解大模型开发
- 模块: 小试牛刀，做一个简单的翻译器
- 课节: 图文 1-3 流式输出与长度控制

1-3 流式输出与长度控制

第4章 第7节 流式输出与长度控制

> [!TIP] 阅读指南 上一节我们完成了多轮对话与上下文管理。现在开始深入API参数——先学习流式输出（stream）和长度控制（max_tokens），这是改善用户体验和控制成本的基础。

7.1 从简单翻译到专业工具

回顾第6节的基础翻译器，它存在几个问题：

- 等待时间长：长文本翻译时，只能干等，看不到进度
- 长度不可控：无法限制翻译结果的长度
- 风格固定：无法调整创意性（直译 vs 意译）
- 成本不透明：不知道消耗了多少Token
- 错误不友好：翻译被截断时没有提示

本节先解决前两个问题

我们将通过2个核心参数来解决：

- stream - 流式输出，解决等待问题
- max_tokens - 控制长度，避免截断

其余参数（temperature、top_p等）将在下一节讨论。

7.2 流式输出

先理解一个大模型开发里常用的方案：流式输出（Streaming）。它常用于改善用户体验。

流式输出的原理

- 非流式：AI生成完整个翻译结果后，一次性返回

非流式

- 流式：AI每生成一小段内容，就立即返回，可以边生成边看到结果

非流式输出：

> 用户输入 → [等待10秒...] → 完整翻译结果一次性显示

流式输出：

> 用户输入 → The → weather → is → really → nice → today → ... ↑ 立即开始 ↑ 逐字输出 ↑ 像打字机一样

流式输出不会让AI生成更快，但会让感知更快。这就是为什么几乎所有现代AI对话产品都使用流式输出。

下面看如何在代码中实现它。

7.3 stream参数实战

> [!TIP] 示例代码位置 本节参考的实际代码位于： /samples/chapter4/translator_pro_plus.py 你可以在项目根目录下找到这个文件，里面包含了完整的流式输出实现。

翻译一篇1000字的文章，需要等待10秒才能看到结果，体验很差。

非流式输出（一次性返回）：

```
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[{"role": "user", "content": "翻译这段文本..."}],
    stream=False  # 默认值
)
print(response.choices[0].message.content)  # 等待10秒后一次性显示
```

流式（逐字返回）：

```
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[{"role": "user", "content": "翻译这段文本..."}],
    stream=True  # 启用流式输出
)

# 不仅要开启stream=True，还需要使用for逐字打印出来
for chunk in response:
    if chunk.choices[0].delta.content:
        print(chunk.choices[0].delta.content, end="", flush=True)
```

实际运行效果

```
非流式：
[等待10秒...]
The weather is really nice today, let's go for a walk in the park.

流式：
The wea[0.1s]ther is [0.1s]really ni[0.1s]ce today[0.1s], let's go[0.1s] for a
walk[0.1s]...
```

max_tokens：长度控制

在第3节中，我们学习了API响应中的finish_reason字段，它会告诉我们生成结束的原因。当finish_reason='length'时，说明是因为达到了Token限制而被截断。下面看如何通过max_tokens参数来控制这个长度。

参数说明

- max_tokens：限制生成的最大Token数（不包括输入）

生成的最大Token数

- 默认值：无限制（由模型自行决定何时停止）
- 最大值：受模型上下文窗口限制（例如：如果模型上下文窗口是128K，输入用了1K，那么输出最多127K）

> Token估算参考 中文：1个汉字 ≈ 1个Token 英文：平均每个单词 ≈ 1.3-1.5个Token（短单词如“the” 是1个，长单词可能被拆分为多个）

使用示例

```
# 限制翻译结果不超过100个Token
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[{"role": "user", "content": "翻译：今天天气真好..."}],
    max_tokens=100  # 最多生成100个Token
)

# 检查是否被截断
if response.choices[0].finish_reason == 'length':
    print("翻译结果被截断，请增加max_tokens或缩短输入")
else:
    print(response.choices[0].message.content)
```

实战建议

- 短文本翻译：max_tokens=200 足够

```
max_tokens=200
```

- 长文章翻译：根据原文长度估算，原文Token数 × 1.5 倍
- 摘要翻译：限制在 max_tokens=50-100，强制精简

```
max_tokens=50-100
```

Token数估算技巧

```
# 粗略估算（中文）
input_chars = len("今天天气真好，我们去公园散步吧。")  # 16个字
estimated_tokens = input_chars * 1  # 约16个Token（1中文字≈1Token）
max_tokens = int(estimated_tokens * 1.5)  # 翻译结果预留1.5倍空间

print(f"输入约{estimated_tokens}个Token，建议max_tokens={max_tokens}")
# 输出：输入约16个Token，建议max_tokens=24
```

7.4 下一节预告

掌握了流式输出和长度控制后，接下来学习如何控制翻译的创意性——通过temperature、top_p等参数，让翻译在直译和意译之间自由切换。

7.5 ■ 学点英语

中文	English	音标	说明
流式输出	Streaming Output	/ˈstriːmɪŋ ˈaʊtpʊt/	AI边生成边返回结果，提升用户体验的技术
最大令牌数	Max Tokens	/mæks ˈtoʊkənz/	限制模型生成内容的最大Token数量
逐块输出	Chunk-by-chunk Output	/tʃʌŋk baɪ tʃʌŋk ˈaʊtpʊt/	流式模式下内容逐步返回的呈现方式
感知速度	Perceived Speed	/pərˈsiːvd spiːd/	用户感受上的响应速度，不等于实际生成速度
截断检测	Truncation Detection	/trʌŋˈkeɪʃn dɪˈtekʃn/	通过finish_reason判断回复是否被截断