第4章 第8节 创意控制与专业翻译器

- 来源: https://class.imooc.com/lesson/5269#mid=104909
- 阶段: 阶段二: 【实战入门】大模型开发与知识接入
- 周: 第4周 理解大模型开发
- 模块: 小试牛刀，做一个简单的翻译器
- 课节: 图文 1-4 创意控制与专业翻译器

1-4 创意控制与专业翻译器

第4章 第8节 创意控制与专业翻译器

> [!TIP] 阅读指南 上一节学习了流式输出和长度控制。现在继续深入——通过temperature、top_p调整翻译风格，通过stream_options获取Token统计，最后整合所有参数打造一个专业翻译器。

8.1 temperature：创意性控制

在第1章，我们学习了Temperature的原理——它通过调整概率分布的"尖锐度"，控制AI选词的随机性。现在看如何在翻译中应用这个原理。

在翻译时，有时需要直译（准确），有时需要意译（自然）。这个需求可以使用Temperature参数来调整。

参数说明

- temperature：控制输出的随机性/创意性
- 取值范围：0.0 - 2.0

```
0.0 - 2.0
```

- 默认值：1.0

```
1.0
```

效果对比

以"今天天气真好，我们去公园散步吧。"翻译为例，看看不同Temperature的效果：

temperature	特点	适用场景	翻译风格
- 0.3	确定性强、一致性高	技术文档、法律合同	直译、逐字对应
- 1.0	平衡（默认）	日常对话、新闻	自然、地道
- 2.0	创意性强、多样性高	文学作品、营销文案	意译、灵活表达

实际示例

```
text = "今天天气真好，我们去公园散步吧。"

# temperature=0（直译）
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[{"role": "user", "content": f"翻译成英文：{text}"}],
    temperature=0.0 # 意译：改为1.5试试
)
print(response.choices[0].message.content)
# 直译输出：Today's weather is really good, let's go to the park for a walk.
# 意译输出：What a beautiful day! How about a stroll in the park?
```

> 核心要点 temperature 不影响质量，只影响风格。低温确定性高，高温创意性强。

8.2 top_p：精细控制多样性

第1章还讲了另一个参数Top-p（核采样），它不是调整整个概率分布，而是动态选择"累积概率达到p"的候选词范围。

- top_p：核采样（nucleus sampling），控制候选词范围
- 取值范围：0.0 - 1.0

```
0.0 - 1.0
```

推荐用法

```
# 推荐：只调一个参数
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[...],
    temperature=0.7  # 只设置temperature
)

# 不推荐：同时调整两个参数（除非很清楚在做什么）
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[...],
    temperature=0.7,
    top_p=0.9  # 同时设置会相互影响，难以预测
)
```

典型取值

- top_p=0.9：保留累积概率90%的候选词（稍微收敛）
- top_p=0.5：保留累积概率50%的候选词（明显收敛）

```
top_p=0.5
```

- top_p=1.0：不限制（默认值）

```
top_p=1.0
```

> 实用建议：优先调整 temperature，只在需要极致精细控制时才考虑 top_p。

8.3 流式输出中的Token统计

在使用流式输出时，可能会发现一个问题：看不到Token消耗统计了。这是因为流式输出默认不返回usage信息。

配置stream_options

```
response = client.chat.completions.create(
    model="qwen3.6-plus",
    messages=[{"role": "user", "content": "翻译这段文本..."}],
    stream=True,
    stream_options={"include_usage": True}  # 在流式输出中包含Token统计
)

for chunk in response:
    if chunk.choices[0].delta.content:
        print(chunk.choices[0].delta.content, end="", flush=True)

    # 最后一个chunk包含usage信息
    if hasattr(chunk, 'usage') and chunk.usage:
        print(f"\n\nToken统计：{chunk.usage.total_tokens}个")
```

输出示例

```
The weather is really nice today, let's go for a walk in the park.

Token统计：28个
```

流式输出默认不返回 usage，需要显式配置 stream_options。

8.4 完整实战：专业翻译器

现在，整合所有参数，打造一个专业级翻译器。

代码参考

> [!TIP] 完整源码参考：samples/chapter4/translator_pro_plus.py

运行这个翻译器，输入想翻译的文本：

运行效果

```
欢迎使用专业翻译器！
支持的风格：直译/平衡/意译
--------------------------------------------------
请输入要翻译的文本（输入'quit'退出）：取次花丛懒回顾半缘修道半缘君
目标语言（默认'英文'）：
翻译风格（直译/平衡/意译，默认'平衡'）：
翻译结果：Passing through gardens of flowers, I seldom look back—
Half for the path of cultivation, half for you.
Token消耗：102个

请输入要翻译的文本（输入'quit'退出）：取次花丛懒回顾半缘修道半缘君
目标语言（默认'英文'）：
翻译风格（直译/平衡/意译，默认'平衡'）：直译
翻译结果：Passing by gardens of flowers, I lazily look back—
Half for the sake of cultivation, half for your sake.
Token消耗：105个

请输入要翻译的文本（输入'quit'退出）：取次花丛懒回顾半缘修道半缘君
目标语言（默认'英文'）：
翻译风格（直译/平衡/意译，默认'平衡'）：意译
翻译结果：Passing through gardens of blossoms, I barely glance back—
half for the path of cultivation, half for you.
Token消耗：104个
```

max_tokens说明

源码默认没有设置max_tokens参数。但如果尝试更改max_tokens参数会发现一个问题。

上述测试结果表明Token消耗大致在100~105个。按照这个思路，将max_tokens设置为50，按理说输出应该被截断——50远小于104。

但实际上模型依然会正确输出翻译。原因在于，max_tokens指的是模型输出的Token，而计算的104个Token消耗还包含了输入部分。max_tokens实际上只应用于以下文本：

这段文本的长度小于50，所以模型输出不会被截断。

8.5 ■ 学点英语

中文	English	音标	说明
温度参数	Temperature	/ˈtemprətʃər/	控制AI输出随机性和创意性的核心参数
核采样	Top-p (Nucleus Sampling)	/tɑp piː ˈnuːkliəs ˈsæmplɪŋ/	动态选择累积概率达到p的候选词范围
创意控制	Creativity Control	/ˌkriːeɪˈtɪvəti kənˈtroʊl/	通过temperature等参数调节AI输出风格
流式选项	Stream Options	/striːm ˈɑːpʃənz/	流式输出中额外配置项（如include_usage）
专业翻译器	Professional Translator	/prəˈfeʃənl trænsˈleɪtər/	整合多参数控制实现风格可调的专业翻译工具

8.7 下一节预告

掌握了API参数后，已经能灵活控制AI的输出。除了调参数，还有什么方法能让AI更准确地理解意图？

下一节学习 Prompt基础与必要场景——了解提示词工程的适用场景和核心方法。

Prompt基础与必要场景