第5章 第12节 LlamaIndex（二）-实战：Java规范问答系统

- 来源: https://class.imooc.com/lesson/5274#mid=104924
- 阶段: 阶段二: 【实战入门】大模型开发与知识接入
- 周: 第5周 RAG：知识接入技术
- 模块: LlamaIndex
- 课节: 图文 1-2 LlamaIndex（二）-实战：Java规范问答系统

1-2 LlamaIndex（二）-实战：Java规范问答系统

第5章 第12节 LlamaIndex（二）-实战：Java规范问答系统

12.1 实战：Java编程规范问答系统

还记得第8节我们手写的Java编程规范问答系统吗？那个系统需要：

```
1. PDF提取：用pdfplumber提取文本
2. 文本清洗：手写正则去除干扰
3. 结构化分块：手写规则识别条目
4. 向量化：调用Embedding API
5. 入库：手动操作Chroma
6. 查询：手动检索 + 拼接上下文 + 调用LLM

总代码：约200行
```

现在，用LlamaIndex重写这个系统，看看能简化多少。

> [!TIP] 完整源码参考：samples/chapter5/llamaindex/java_qa_llamaindex.py

场景回顾

在第8节，我们手写了一个完整的Java编程规范问答系统：

目标 做一个能回答Java编程规范问题的智能助手

目标

数据源 阿里巴巴Java开发手册（PDF，37页，约4万字）

数据源

用户问题示例

```
Q: "Java左大括号应该换行还是不换行？"
A: "根据《Java编程规范》：左大括号前不换行，左大括号后必须换行..."

1
2
```

核心实现

在实际项目中，我们使用的是自定义分块策略（详见10.4.3节）。因为Java规范需要按条目切分，而不是用LlamaIndex的默认分块。

步骤1 读取数据并结构化分块

```
# 1. 读取示例数据（与第8节相同sample_data.txt）
with open(SAMPLE_DATA_PATH, 'r', encoding='utf-8') as f:
    text = f.read()

# 2. 使用自定义的结构化分块函数（复用第8节逻辑）
chunks = structure_based_chunking(text)
# 按【强制】【推荐】等条目切分，共50个chunk

# 3. 包装成Document对象
documents = [
    Document(
        text=chunk,
        metadata={"chunk_id": i, "source": "Java开发手册"}
    )
    for i, chunk in enumerate(chunks)
]
# 这样LlamaIndex就不会再次切分，直接使用我们的chunks
```

> 为什么不用LlamaIndex的Reader？ LlamaIndex提供了PDFReader、SimpleDirectoryReader等多种Reader，可以自动读取各种格式。但我们的场景需要结构化分块（按条目），所以选择自己分好块再交给LlamaIndex。

步骤2 构建索引

```
index = VectorStoreIndex.from_documents(documents)

1
```

LlamaIndex自动完成向量化和存储。

步骤3 持久化存储

```
# 首次运行：构建并保存
index.storage_context.persist(persist_dir="kb/")

# 之后运行：直接加载
from llama_index.core import StorageContext, load_index_from_storage
storage_context = StorageContext.from_defaults(persist_dir="kb/")
index = load_index_from_storage(storage_context)
```

步骤4 查询

```
query_engine = index.as_query_engine(
    similarity_top_k=3,
    response_mode="compact"
)

response = query_engine.query("变量命名有什么规范？")
print(response)
```

运行效果

运行示例

```
$ python samples/chapter5/llamaindex/java_qa_llamaindex.py

==========================================
离线处理：构建Java编程规范知识库（LlamaIndex版）
==========================================

[1/5] 加载示例数据...
✓ 加载完成，共50个chunk

[2/5] 构建VectorStoreIndex...
Generating embeddings: 100%|█| 50/50 [00:03<00:00]
✓ 索引构建完成

[3/5] 持久化存储...
✓ 知识库已保存到：kb/

==========================================
Java编程规范问答系统（LlamaIndex版）
==========================================

请输入问题（输入q退出）：变量命名有什么规范？

思考中...

【答案】
变量命名应使用完整、清晰的单词组合，力求语义表达完整清楚。
常量命名需全部大写，单词间用下划线隔开。

【引用来源】
[1] 相似度：70.05%
    16. 【参考】各层命名规约...
[2] 相似度：67.02%
    5. 【强制】常量命名全部大写...
[3] 相似度：64.57%
    11. 【推荐】为了达到代码自解释的目标...
```

12.2 下节预告

到这里，我们已经掌握了RAG的核心技术：从原理讲解到检索优化，从手写实现到LlamaIndex框架。但你可能已经意识到，传统RAG总是被动地等待用户提问，然后一次性检索并返回结果——它不会主动思

考"这个问题是否需要检索"“检索结果是否足够”“要不要换个角度再查查”。下一章，我们将进入第4章，系统讲解 Function Calling，让大模型不仅会回答问题，还能主动调用工具完成更复杂的任务。

12.3 ■ 学点英语

中文	English	音标	说明
手写实现	Manual Implementation	/ˈmænjuəl ɪmplɪmenˈteɪʃn/	不依赖框架，从零编写所有RAG流程代码的方式
框架自动化	Framework Automation	/ˈfreɪmwɜːrk ˌɔːtəˈmeɪʃn/	利用框架封装好的功能简化开发流程
可维护性	Maintainability	/meɪnˌteɪnəˈbɪləti/	代码易于修改、扩展和排错的特性
管道化处理	Pipeline Processing	/ˈpaɪplaɪn ˈprɑːsesɪŋ/	将数据处理流程组织为有序的阶段式处理链